

EKONOMICKÁ UNIVERZITA V BRATISLAVE
FAKULTA HOSPODÁRSKEJ INFORMATIKY

Evidenčné číslo: 103006/I/2022/421000162362

**Analýza výnosov akciových trhov využitím
neurónových sietí**

Diplomová práca

2022

Provazník Patrik

EKONOMICKÁ UNIVERZITA V BRATISLAVE
FAKULTA HOSPODÁRSKEJ INFORMATIKY

**Analýza výnosov akciových trhov využitím
neurónových sietí**

Diplomová práca

Študijný program: Informačný manažment

Študijný odbor: Ekonómia a manažment

Školiace pracovisko: Katedra matematiky a aktuárstva

Vedúci záverečnej práce: Mgr. Andrea Kaderová, PhD.

ABSTRAKT

Provazník, Patrik: *Analýza výnosov akciových trhov využitím neurónových sietí*. – Ekonomická univerzita v Bratislave. Fakulta hospodárskej informatiky; Katedra matematiky a aktuárstva. – Vedúci záverečnej práce: Mgr., Andrea Kaderová, PhD. – Bratislava: FHI, 2022, počet strán 66.

Cieľom záverečnej práce je poukázať na možnosti využitia umelej inteligencie, konkrétne neurónových sietí pri analýze výnosov akciových trhov. Práca je rozdelená do troch kapitol. Prvá kapitola je venovaná metódam a technikám, ktoré sa využívajú pri analýze výnosov akciových trhov, a taktiež charakterizovaniu prostriedkov neurónových sietí. V druhej kapitole charakterizujeme hlavný cieľ a čiastkové ciele záverečnej práce, metódy a metodiky, ktoré sme využívali pri napĺňaní hlavného cieľa a čiastkových cieľov tejto práce. Záverečná kapitola sa zaoberá implementáciou programu na predikciu cien akcií danej spoločnosti s využitím modelu LSTM rekurentnej neurónovej siete. Výsledkom riešenia danej problematiky je program, ktorý je schopný vytvárať predikcie cien akcií na základe historických údajov týkajúcich sa uzatváracích cien akcií určitej spoločnosti.

Kľúčové slová: akciový trh, fundamentálna analýza, psychologická analýza, technická analýza, neurónové siete, rekurentné neurónové siete, LSTM, predikcia, Keras

ABSTRACT

Provaznik, Patrik: *Analysis of stock market returns using neural networks*. - University of Economics in Bratislava. Faculty of Business Informatics; Department of Mathematics and Actuarial. - Thesis supervisor: Mgr., Andrea Kaderova, PhD. - Bratislava: FHI, 2022, number of pages 66.

The aim of the final thesis is to point out the possibilities of using artificial intelligence, specifically neural networks in the analysis of stock market returns. The work is divided into three chapters. The first chapter is devoted to the methods and techniques used in the analysis of stock market returns, as well as the characterization of neural network resources. In the second chapter we characterize the main goal and partial goals of the final work, methods and methodologies that we used in fulfilling the main goal and partial goals of this work. The final chapter deals with the implementation of a program for predicting the share prices of a given company using the LSTM model of a recurrent neural network. The result of solving this problem is a program that is able to create stock price predictions based on historical data regarding the closing prices of shares of a particular company.

Keywords: stock market, fundamental analysis, psychological analysis, technical analysis, neural networks, recurrent neural networks, LSTM, prediction, Keras

Obsah

Úvod.....	7
1 Súčasný stav riešenej problematiky	9
1.1 Analýza akciových trhov.....	9
1.2 Fundamentálna analýza	11
1.2.1 Fundamentálna analýza zhora nadol a zdola nahor	13
1.2.2 Globálna (makroekonomická) úroveň fundamentálnej analýzy	14
1.2.3 Odvetvová úroveň fundamentálnej analýzy	15
1.2.4 Fundamentálna analýza jednotlivých spoločností	15
1.3 Psychologická analýza	16
1.3.1 Koncepty psychologické analýzy	16
1.4 Technická analýza.....	18
1.4.1 Metódy technickej analýzy	19
1.5 Neurónové siete.....	21
1.5.1 Biologický verus umelý neurón	21
1.5.2 Typy aktivačných funkcií	24
1.5.3 Štruktúra neurónovej siete	25
1.5.4 Trénovanie neurónovej siete	26
1.6 Rekurentné neurónové siete	28
1.6.1 Problémy rekurentných neurónových sietí	31
1.6.2 LSTM - Long short-term memory	31
2 Cieľ práce, metodika práce a metódy skúmania.....	33
2.1 Cieľ práce	33
2.2 Metodika práce a metódy skúmania.....	34
3 Výsledky práce	37
3.1 Implementácia programu	37
3.1.1 Načítanie dát	38
3.1.2 Príprava dát na trénovanie neurónovej siete	39
3.1.3 Vytvorenie a trénovanie LSTM modelu neurónovej siete.....	41
3.1.4 Testovanie modelu	44
3.1.5 Vykreslenie predikcií	47
3.1.6 Predikcia ceny akcií nasledujúceho dňa	48
3.2 Zhodnotenie výsledného programu a pohľad do budúcnosti	49

3.3	Prehľad použitých technológií	51
3.4	Diskusia.....	54
Záver		57
Použitá literatúra		58
Prílohy.....		64

Zoznam obrázkov

Obrázok 1: Biologický neurón	22
Obrázok 2: Umelý neurón	23
Obrázok 3: Sigmoidná aktivačná funkcia	24
Obrázok 4: Aktivačná funkcia hyperbolický tangens	25
Obrázok 5: Aktivačná funkcia ReLU	25
Obrázok 6: Rekurentná a dopredná neurónová sieť	29
Obrázok 7: Typy rekurentných neurónových sietí	30
Obrázok 8: Výpis historických údajov spoločnosti Tesla	38
Obrázok 9: Prevedenie uzatváracích cien akcií do 2D poľa	39
Obrázok 10: Ukážka škálovania uzatváracích cien	40
Obrázok 11: Model LSTM rekurentnej neurónovej siete	42
Obrázok 12: Graf výkonnosti vytvoreného modelu v jednotlivých epochách	44
Obrázok 13: Prevedenie testovacích uzatváracích cien akcií do 2D poľa	45
Obrázok 14: Prevedenie výsledných predikcií na reálne ceny akcií	47
Obrázok 15: Graf skutočných a predikovaných uzatváracích cien spoločnosti Tesla	48
Obrázok 16: Graf výkonnosti modelu na dátach spoločnosti Cedar Fair	55
Obrázok 17: Graf skutočných a predikovaných uzatváracích cien Cedar Fair	56

Úvod

Akciový trh ľudia vnímajú ako svet špekulácii, prijímania rizík, snahy predpovedať budúci cenový vývoj, predovšetkým však spojený s nádejou na vysoký zisk, tak ako to častokrát býva zobrazované vo filmoch z finančného prostredia veľkých korporácií a firiem. Je miestom, kde sa odohrala veľká hospodárska kríza dvadsiatych a tridsiatych rokov 20. storočia, a stále slúži ako ukazovateľ modernej ekonomiky. Akciový trh predstavuje priestor pre obchodovanie s cennými papiermi, predovšetkým akciami.

Odhad vývoja ceny ako aj realizovaného objemu transakcií na akciových trhoch umožnili rôzne analýzy. Ako prvé je potrebné zmieniť sa o metóde technickej analýzy, ktorá sa v prvom rade zaujíma len o výslednú cenu, nezaujíma sa o príčiny zmien v dopyte a ponuke, čo predstavuje predpoklad podobný silnej a stredne silnej forme trhovej ekonomiky. Jej cieľom je zachytiť vývoj obchodovania s určitými cennými papiermi na akciových trhoch, prípadne indexoch a potom zo znázornenej histórie sa pokúsiť určiť pravdepodobný vývoj, ktorý ešte len nastane. Ako druhú si spomenieme metódu fundamentálnej analýzy akcií, ktorá analyzuje stav vývoja národného hospodárstva, determinuje stav v hodnotenom odvetví, určuje finančnú schopnosť v danej firme, a stanovuje hodnotu akcií danej firmy. Napokon je potrebné zahrnúť k týmto metódam analýz aj metódu psychologickéj analýzy. Táto analýza vychádza z predpokladu, že úroveň kurzov je ovplyvnená tým, že masová psychológia publika na burze má silný vplyv na burzové trhy, a to tak, že pôsobí na účastníkov trhu a ich priame konanie. Správanie davu ovplyvňujú impulzy, od ktorých závisí budúci vývoj kurzov cenných papierov, a podľa tohto správania účastníkov trhu, sa títo následne prikláňajú k nákupu alebo predaju cenných papierov.

S postupným rastom a zdokonaľovaním výpočtovej techniky, prichádzajú pre investorov nové možnosti pri predikcii budúceho cenového vývoja základového aktíva. Jedná sa o systémy umelej inteligencie. Medzi tie najpoužívanéjšie patria neurónové siete, genetické algoritmy a systémy fuzzy logiky.

Spojením týchto analýz so systémami umelej inteligencie je možné spracovávať obrovské množstvo dát, a tým získať nástroj, ktorý je oproti možnostiam človeka v značnej výhode. Táto kombinácia spolu s človekom, jeho skúsenosťami a znalosťami by mala poskytovať investorom podporu pri rozhodovaní na akciových trhoch, a taktiež znižovať

mieru rizika neúspechu na čo najnižšiu možnú úroveň. Využitím takýchto techník sa spoločnostiam otvárajú nové možnosti ako sa pokúsiť o zhodnotenie voľných peňažných prostriedkov. Vďaka všetkým prednostiam výpočtovej techniky má význam sa pri obchodovaní zaoberať technickou analýzou a využívať ju, avšak ľudia by nemali na finančný trh vstupovať odborne a psychicky nepripravení.

Táto práca bude pojednávať práve o využití prostriedkov umelej inteligencie ako podpora v procese rozhodovania na akciových trhoch.

1 Súčasný stav riešenej problematiky

V tejto kapitole si poskytneme komplexný pohľad na potrebné teoretické poznatky, ktoré sú dôležité pri odhadovaní budúceho cenového vývoja na akciových a im podobných trhoch. V ďalších podkapitolách následne upriamime pozornosť na základné pojmy a princípy, týkajúce sa fungovania akciových trhov a na fundamentálne faktory, vstupujúce do finálneho stanovenia cien aktív. Pomedzi tieto faktory zaradíme predovšetkým základné činitele v globálnom meradle, ďalej na odvetvovej úrovni, na úrovni jednotlivých spoločností a taktiež aj rovnako významné technické i psychologické ukazovatele. Detailnejšie si vysvetlíme bežne zaužívané postupy a techniky, ktoré sa používajú pri predikciách a analýzach cien a taktiež objemov transakcií na akciových a im príbuzných trhoch. Priblížime si aj najnovšie postupy, ktoré sú založené na báze umelej inteligencie, kde konkrétne venujeme pozornosť umelým neurónovým sieťam.

1.1 Analýza akciových trhov

Predmetom tejto podkapitoly bude určenie základných pojmov, ktoré súvisia s akciovými trhmi a ich následnou analýzou. Predtým, ako prikróčíme k problematike akciových trhov, bude potrebné ich definovať zo širšieho pohľadu, hlavne vymedziť ich miesto na finančnom trhu.

„Trh definujeme ako mechanizmus, na základe ktorého sa kupujúci a predávajúci stretávajú, aby určili cenu tovaru a jeho množstvo, ktoré sa nakúpi a predá.“ (Samuelson, Nordhaus, 2007)

Finančný trh je vo všeobecnosti možné charakterizovať rovnako ako akýkoľvek iný trh. Tvorí vrchol všetkých trhov a zároveň jadro finančného systému. Finančný trh je univerzálny trh a je miestom, kde sa stretáva na jednej strane ponuka voľných finančných prostriedkov v podobe úspor rôznych ekonomických subjektov ako sú domácnosti, firmy, vládne inštitúcie a zahraničné subjekty a na druhej strane dopyt rôznych ekonomických subjektov po týchto prostriedkoch, ktoré oni využívajú ako investície. Finančným trhom sa spravidla rozumie súhrn vzťahov, inštitúcií, nástrojov, ktoré umožňujú sústredovanie, rozmiestňovanie a opätovné rozdeľovanie voľných finančných prostriedkov na základe ponuky a dopytu medzi ekonomické subjekty (EuroEkonom, 2020).

Finančný trh môžeme taktiež definovať ako organizačný rámec, v ktorom sa realizuje predaj a nákup finančných inštrumentov. Napriek tomu, že trh charakterizujeme ako miesto, nemusí však mať fyzickú podobu. Prispieva k tomu hlavne rozvoj informačných technológií, čo pre finančné trhy predstavuje geografickú neobmedzenosť. Geografická neobmedzenosť vedie k internacionalizácii a interdependencii finančných trhov, ale súčasne na druhej strane vyvoláva potrebu medzinárodnej regulácie. Úlohou finančného trhu je predovšetkým sústredenie voľných zdrojov peňažných prostriedkov, ich alokácia tam, kde je ich využitie najefektívnejšie a napokon prerozdeľovanie, čiže premena úspor na investície. Finančné prostriedky premiestňujeme od prebytkových subjektov (investorov, veriteľov) k nedostatkovým subjektom (dlžníkom, emitentom), čím sa zosúladujú investície s úsporami. Pohyb týchto finančných prostriedkov je realizovaný dvoma spôsobmi a to pomocou priameho a nepriameho financovania. Na základe priameho financovania získavajú nedostatkové subjekty finančné prostriedky od prebytkových subjektov priamo tým spôsobom, že predávajú svoje cenné papiere, ktoré predstavujú pohľadávku prebytkového subjektu (veriteľa) voči nim.

Najčastejšie sa finančný trh člení z časového hľadiska, a to na peňažný a kapitálový trh. Peňažný trh je charakterizovaný ako trh krátkodobých úverov a iných finančných nástrojov so splatnosťou do jedného roka. Naopak účelom kapitálového trhu je zabezpečiť dlhodobé zdroje financovania, resp. peňažný kapitál. Je to trh dlhodobých úverov a finančných nástrojov, ktoré majú splatnosť viac ako jeden rok. Kapitálový trh sa ďalej delí na akciový, dlhopisový a derivátový. Pre potreby tejto práce sa ďalej budeme zameriavať na akciový trh.

Z vecného hľadiska do finančného trhu patria okrem peňažného a kapitálového trhu taktiež aj trh poisťný, devízový a komoditný. Pod poisťným trhom rozumieme trh poistenia a zaistenia osôb, majetku a zodpovednosti za škodu. Produktom na poisťnom trhu je poisťná ochrana. Devízový trh je charakterizovaný ako miesto, kde sa stretáva ponuka a dopyt po cudzích menách, resp. devízach a kde sa tvorí devízový kurz. Komoditný trh slúži najmä pre špekulácie na pohyby cien určitých aktív. Jedná sa najčastejšie o derivátové obchody, kde podkladovým aktívom je daná komodita. Ide napríklad o drahé kovy, nehnuteľnosti a iné komodity (energie, umelecké predmety, obilniny atď...) (Amadeo, 2022).

Ako sme už spomenuli, kapitálový trh štandardne členíme na akciový, dlhopisový a derivátový. Pod akciovým trhom rozumieme miesto, kde sa stretáva ponuka a dopyt

po rôznych druhoch akciách a tvorí sa trhovú cenu. Patria sem všetky verejne obchodované akcie a podielové listy. Akcia predstavuje majetkový cenný papier. Predstavuje podiel vlastníka, resp. akcionára na základnom imaní danej akciovej spoločnosti a poskytuje mu isté práva ako podieľať sa na riadení, zisku (dividendy), likvidačnom zostatku, poskytuje mu informačné právo a taktiež predkupné právo pri novej, dodatočnej emisii akcií.

Nás však bude zaujímať ďalšie členenie, ktoré vychádza z rozdielného pohľadu na analýzu akciových trhov. Vo všeobecnosti hovoríme o troch základných prístupoch, ktoré trhové subjekty využívajú pri skúmaní akciových trhov:

- **fundamentálnej analýza**
- **technickej analýza**
- **psychologickej analýza.**

1.2 Fundamentálna analýza

Fundamentálna analýza je metóda, ktorú investori používajú na identifikáciu tzv. vnútornej hodnoty akcie (intrinsic value). Akcie môžu byť na trhu nadhodnotené alebo podhodnotené, čo znamená, že aktuálne ceny akcií nemusia odrážať ich skutočnú hodnotu. Táto vnútorná hodnota je potrebná na porovnanie s aktuálnou trhovou cenou akcie a na rozhodnutie o investícii. Ak je teda trhovú cenu akcií nad ich vnútornou hodnotou, investor by mal akcie predat' alebo vstúpiť do krátkej pozície, pretože akcie sú nadhodnotené a ich ceny budú z dlhodobého hľadiska klesať alebo naopak. Úlohou fundamentálnych analytikov je teda skúmať životnosť spoločnosti, za účelom identifikácie vnútornej hodnoty danej spoločnosti. To sa dosahuje použitím rôznych kvalitatívnych a kvantitatívnych faktorov, ako sú príjmy spoločnosti, ziskové marže, návratnosť vlastného kapitálu, potenciál budúceho rastu a ďalšie iné metriky. Hlavným účelom tejto metódy je preto určiť také spoločnosti, ktoré sú od základu silné, aby bolo možné do nich dlhodobo investovať (Edelweiss, 2021).

Rozlišujeme dva typy fundamentálnej analýzy:

Kvantitatívna fundamentálna analýza - sa zameriava na verejne dostupné finančné údaje spoločnosti, ako sú výnosy, pomer ceny a zisku, návratnosť vlastného kapitálu a ďalšie. Kvantitatívna analýza je založená na financiách spoločnosti alebo inými slovami na merateľných charakteristikách podnikania. Pri tejto analýze používame účtovnú závierku

na čerpanie informácií o finančnej výkonnosti a súčasnom ekonomickom stave spoločnosti, teda sledujeme tri dôležité ukazovatele:

- **výkazy ziskov a strát** - uvádzajú výkonnosť spoločnosti za konkrétne časové obdobie.
- **súvahy** - poskytujú prehľad aktív, pasív a vlastného imania spoločnosti v konkrétnom časovom okamihu.
- **výkaz peňažných tokov** - je tiež nápomocný, pretože predstavuje všetky peňažné pohyby (príjmy a výdavky) za konkrétne časové obdobie

Kvalitatívna fundamentálna analýza - je subjektívnejšia, pretože sa opiera o nemerateľné údaje, ako sú znalosti manažmentu, konkurencia v odvetví, stav ekonomiky ako celku a mnoho ďalších makroekonomických alebo mikroekonomických faktorov ovplyvňujúcich výkonnosť podniku. Niektoré zo základných informácií, ktoré musíme pri vykonávaní tohto typu analýzy zvážiť, sú:

- **Rozpoznávanie a asociácia značky** - či samotná značka ovplyvňuje cenu akcie. Cena akcií spoločnosti Apple napríklad odzrkadľuje, že má jednu z najsilnejších pozitívnych asociácií značiek.
- **Konkurenčná výhoda** - dostupnosť faktorov, ktoré umožňujú spoločnosti dosahovať lepšie výsledky ako jej konkurenti, má pozitívny vplyv na vnútornú hodnotu podniku.
- **Výkonnosť manažmentu** - analytici sa domnievajú, že toto je základná charakteristika spoločnosti pri rozhodovaní, či je výhodné do nej investovať.
- **Spokojnosť zákazníkov** - silná a spokojná zákaznícka základňa predstavuje veľkú hodnotu pre cenu spoločnosti.
- **Správa a riadenie spoločnosti** - Investori potrebujú presné informácie o tom, či spoločnosť podniká eticky, spravodlivo a transparentne.

Pretože sú tieto dva typy fundamentálnej analýzy v podstate úplne odlišné, nemôžeme povedať, čo je hodnotnejšie, a preto investori používajú kombináciu oboch, aby tak mohli odvodiť reálnu trhovú hodnotu cieľovej investície (Mitev, 2021).

1.2.1 Fundamentálna analýza zhora nadol a zdola nahor

Pri hľadaní investičných príležitostí na akomkoľvek akciovom trhu môžu investori postupovať podľa základných krokov ekonomických prístupov. Pri fundamentálnej analýze sa používajú dva základné prístupy:

Prístup zhora nadol (Top-Down Approach) – Investovanie „zhora nadol“ znamená začať analýzu zo širšej perspektívy a potom prejsť na ďalšie špecifické faktory. Pri prístupe „zhora nadol“ investori ako prvé posúdia makroekonomické faktory, ktoré ovplyvňujú trhy. Potom identifikujú odvetvia, ktoré by si vzhľadom na hodnotené makroekonomické faktory počínali dobre. Nakoniec sa vyfiltrujú akcie patriace do odvetví, o ktorých sa investori domnievajú, že by mali dobrú výkonnosť a investujú do daného akciového trhu. Ako príklad môžeme spomenúť stav počas pandémie COVID, kedy sa ekonomika spomalila a zdravotnícky a farmaceutický sektor sa stal veľmi žiadaný. Vzhľadom na makroekonomický trend pandémie si teda farmaceutický sektor vedie dobre, a preto môžeme investovať do farmaceutických akcií s cieľom dosiahnuť dobrú návratnosť. Model investovania „zhora nadol“ používa pri výbere akcií nasledujúce faktory:

- HDP sveta,
- ekonomický rast krajín,
- menová politika,
- ekonomická inflácia a pohyb cien komodít,
- ceny dlhopisov a ich súčasné a očakávané výnosy.

V metóde fundamentálnej analýzy zhora nadol teda existujú tri všeobecné kroky. Prvotným krokom je ekonomická prognóza, nasleduje identifikácia vhodných odvetví a ako posledné sa analyzujú určité spoločnosti. Na základe týchto krokov rozoznávame 3 úrovne fundamentálnej analýzy, a to globálnu, odvetvovú a fundamentálnu analýzu jednotlivých spoločností. Každý z týchto úrovní sa budeme venovať postupne v nasledujúcich kapitolách fundamentálnej analýzy.

Prístup zdola nahor (Bottom-Up Approach) - Investičný prístup „zdola nahor“ je úplným opakom spôsobu investovania „zhora nadol“. V rámci analýzy „zdola nahor“ začneme tým, že zhodnotíme základy konkrétnej spoločnosti, porovnáme tieto základy s jej konkurentmi a potom zhodnotíme, či sa do akcie oplatí investovať. Pri investovaní „zdola

nahor“ investori najskôr zhodnotia a vyberú konkrétne akcie namiesto posudzovania širších makroekonomických faktorov, pritom berú do úvahy tieto rozhodujúce faktory:

- finančné ukazovatele spoločnosti vypočítané pomocou účtovnej závierky spoločnosti (pomer ceny a zisku, návratnosť vloženého kapitálu, ziskové marže,...),
- aktuálne a očakávané zárobky,
- príjmy spoločnosti,
- trendová analýza obratu spoločnosti,
- analýza peňažných tokov spoločnosti,
- produkty ponúkané spoločnosťou, ich dopyt, podiel na trhu,
- vedenie spoločnosti,
- výkon spoločnosti voči svojim konkurentom (Bpwealth, 2021).

1.2.2 Globálna (makroekonomická) úroveň fundamentálnej analýzy

Prístup zhora nadol je najpoužívanejšou metódou implementácie fundamentálnej analýzy. Ako sme už spomínali v predchádzajúcej kapitole tento prístup začína analýzou globálnej ekonomiky. To znamená starostlivo študovať pozíciu ekonomických lídrov vo svete, čo spolu s rozvinutými krajinami zahŕňa aj ekonomiky rýchlo rastúcich rozvojových krajín. Globálna ekonomika má vplyv na každú krajinu a vďaka globalizácii má vplyv na každé odvetvie, v dôsledku čoho je nevyhnutné študovať jej stav. Keď získame predstavu o stave globálnej ekonomiky, musíme začať výskum o aktuálnom stave národného hospodárstva. Pretože investície do konkrétnej akcie sú v konečnom dôsledku pod vplyvom národného HDP, vyšší HDP často vedie k vyššej ziskovosti odvetví. Spolu s grafmi HDP nesmieme ignorovať ani obchodné cykly v ekonomike. Je veľmi dôležité správne odhadnúť hospodárske cykly, aby sme vedeli, kedy sa ekonomika nachádza v období útlmu a kedy v stave expanzie. Pri štúdiu národného hospodárstva je potrebné vziať do úvahy aj ďalšie makroekonomické ukazovatele, ako je miera inflácie, úrokové sadzby, ponuka peňazí atď. Globálni investori by mali taktiež posúdiť politickú situáciu krajiny predtým, ako sa do nej rozhodnú investovať. Ako investori by sme mali určiť, či je ekonomika krajiny ohrozená. Dôvodom môže byť jej vlastný politický stav alebo situácie, v ktorých susedné krajiny môžu ohrozovať jej ekonomiku. Napríklad, keď Ruská federácia v roku 2014 anektovala Krym, riziko investovania vo východnej Európe sa výrazne zvýšilo (Ganju, 2018).

1.2.3 Odvetvová úroveň fundamentálnej analýzy

Ďalším krokom v prístupe zhora nadol je posúdenie ekonomickej a finančnej situácie daného sektora hospodárstva, ktoré sa nazýva sektorová analýza. Poskytuje investorovi úsudok o tom, ako efektívne môžu spoločnosti v tomto sektore fungovať. Sektorová analýza je založená na predpoklade, že v rôznych fázach hospodárskeho cyklu dosahujú niektoré sektory lepšie výsledky. Hospodársky cyklus pozostáva z expanzií, ktoré sú obdobiami ekonomického rastu a kontrakcií, ktoré sú obdobiami ekonomického poklesu. Počas fázy expanzie by investori alebo analytici, ktorí vykonávajú sektorovú analýzu, by mali zamerať svoj výskum na spoločnosti, ktoré ťažia z nízkych úrokových sadziieb a zvýšených kapitálových nákladov. Napríklad spoločnostiam sa vo finančných a cyklických spotrebiteľských sektoroch počas obdobia ekonomického rastu zvyšuje výkonnosť. Na druhej strane, počas ekonomickej recesie, kedy sa ekonomika a jej rast spomalia, investori a analytici obracajú svoju pozornosť na odvetvia, ako sú napríklad verejné služby a telekomunikačné služby, pretože tieto odvetvia často prekonávajú ekonomické krízy (Elearnmarkets, 2021).

1.2.4 Fundamentálna analýza jednotlivých spoločností

Keď sú jednotlivé odvetvia kompletne analyzované a zaznamenali sme ich budúcu perspektívu, rast a zdravie, konečne pristúpime k analýze spoločnosti. Na analýzu spoločnosti existujú dve hlavné zložky.

- Najdôležitejším podkladom pre túto úroveň sú finančné výkazy konkrétnej spoločnosti, pomery akcií, technické grafy a správy o plánoch do budúcnosti. Informácie o finančných výkazoch spoločnosti získavajú investori najmä z účtovnej závierky, ktorá by mala pozostávať zo súvahy, výkazu ziskov a strát, výkazu zmien vlastného imania, výkazu peňažných tokov a poznámok. Pre finančnú analýzu sú najvhodnejšie účtovné závierky zostavené podľa medzinárodných účtovných štandardov ako IFRS (International Financial Report Standards) alebo US GAAP (Generally Accepted Accounting Principles in the United States).
- Ďalšou dôležitou zložkou, ktorú investori zohľadňujú pri výbere akcií, je manažment danej spoločnosti. Spoločnosť možno nazvať ziskovou iba vtedy, ak sú jej príjmy vyššie ako náklady a ak má spoločnosť stabilný manažment. Stabilný manažment

znamená, že ľudia riadiaci spoločnosť sú rozumní, múdri a nezapájajú sa do podvodných praktík (Ganju, 2018).

1.3 Psychologická analýza

Psychologický prístup tvorí popri fundamentálnej a technickej analýze ďalšiu vetvu pri rozhodovaní o nákupe či predaji akcie alebo iného aktíva. Psychologický prístup sa na rozdiel od menovaných analýz nezameriava na samotné aktívum, ale na ľudskú psychiku, ktorá podľa tohto prístupu ovplyvňuje najmä pohyb kurzov. Hlavnou otázkou, ktorú si psychologická analýza kladie, je teda to, ako kurz akcie ovplyvňuje správanie a myšlienkový úsudok samotných investorov. Aj keď má psychológia nezastupiteľné miesto pri analýze cenných papierov, popri technickej a fundamentálnej analýze predstavuje pre investorov menej uznávaný zdroj informácií. Základy psychologickému prístupu položil francúzsky psychológ, matematik, sociológ a okrem iného tiež lekár Gustave Le Bon svojou teóriou psychológie davu. Medzi nasledovníkov, ktorí sa prístup snažili rozvinúť formuláciou vlastnej analýzy či teórie, patria napríklad známy investor André Kostolany, pre mnohých v neobvyklej úlohe veľmi úspešného investora John Maynard Keynes, a taktiež napríklad George Drasnar. Všetkým hore menovaným a ich konceptom sa budeme venovať v nasledujúcich podkapitolách.

1.3.1 Koncepty psychologickéj analýzy

Veľmi významným faktorom pri psychologickéj analýze je práve psychologický stav investorov, ktorý ovplyvňuje vývoj kurzov. Zahrňuje veľa teoretických koncepcií, ktoré vysvetľujú vplyv masovej psychológie na vývoj aktív, kde medzi najvýznamnejšie patria:

Le Bonova psychológia davu – Francúzsky sociológ, psychológ, matematik, a tiež lekár Gustave Le Bon stál pri zrode skúmania psychológie davu. Podľa Le Bona vlastnosti davu ako celku presahujú vlastnosti jeho jednotlivých členov. Nie sú teda len súčtom ich individuálnych vlastností, ale vytvárajú sa nové vlastnosti - emócie. Dav jedinca pohltí a potlačí jeho charakter. Ten stráca vlastný racionálny úsudok a začne sa riadiť predovšetkým svojimi inštinktmí, pocitmi a citmi. Davu preto chýba racionalita, na základe čoho Le Bon vyvodzuje, že je pre investora kľúčové spoznať správanie davu. Ten sa ako celok nielen neriadi fundamentmi (fundamentálna analýza), ale ani vývojom a skúsenosťami z minulosti (technická analýza), ale dostáva horúce investičné tipy, vsádza na tipy ďalších

investorov a analytikov bez dominancie vlastného úsudku jednotlivcov a zapojenia ďalších analytických prístupov. Takéto zmanipulovanie davu ho robí len veľmi ťažko čitateľným.

Kostolanyho stratégia – André Kostolany bol narodený v roku 1906 v Budapešti, no väčšinu svojho života pôsobil v Nemecku a Francúzsku. Bol známy najmä svojou prepracovanou a bystrou psychológiou a rozumnou znalosťou akcií a trhov. Na základe teórie davu delil Kostolany účastníkov trhu do dvoch skupín: na špekulantov a hráčov.

- Špekulanti sú tými, ktorí dominujú na trhu a určujú jeho vývoj. Medzi investormi sú nazývaní aj "pevnými rukami" a prisudzujú im vlastnosti zhrnuté vo 4G - z nemčiny to sú Gedanken ako myšlienky, Gedult ako trpezlivosť, Geld ako peniaze a Glück ako šťastie. Špekulanti držia svoje nervy a emócie na uzde, racionálne premýšľajú a robia racionálne rozhodnutia. Nenechajú sa pohltiť emóciami davu a vedia postupovať proti prúdu.
- Opakom špekulantov sú hráči. Tých Kostolany prezýva "roztrasenými rukami". Pre hráčov sú typické neovládnuté emócie a stávky na lacné tipy s vidinou obrovských ziskov. Chýba im vlastný úsudok a idú takzvané s trhom a to zvyčajne neskoro. Keď trh klesá, oni pokles nasledujú a predávajú, keď trh rastie, oni rast (opäť neskoro) nasledujú a kupujú (často pred vrcholom alebo na ňom). Ich správanie je nečitateľné a nepredvídateľné.

Keynesova stratégia – John Maynard Keynes je spájaný predovšetkým s makroekonomiou, avšak nie je príliš známy ako úspešný investor. U investorov podľa neho prevláda krátkodobý investičný horizont, keď sú hnaní za motívom vysokého a rýchleho zbohatnutia v krátkom čase. Medzi investormi rozlišuje taktiež dve základné skupiny, ktorých vymedzenie má spoločné prvky s Kostolanym (Keynesovej teória je ale staršia, než Kostolanyho):

- Individuálni investori podľa Keynesa podliehajú emóciám - vlnám eufórie či naopak pesimizmu. Konajú na základe pocitov a viery v určitú vec a nechávajú sa strhnúť k prehnaným reakciám na menej podstatné impulzy.
- Racionálne vyhodnocujúcim účastníkom trhu je podľa Keynesa investor profesionál. Ten sa psychológiou davu riadi iba ako indikátorom, ktorý ho vedie k opačnému správaniu. Ide proti davu individuálnych investorov, proti prúdu.

Keynes vo svojej stratégii konštatuje aj dva základné motívy k investovaniu, ktoré pomenoval podnikavosť a špekulácia. Podnikavosť podľa neho stojí na odhade

reálneho budúceho výnosu majetkovej hodnoty počas celého obdobia životnosti aktíva. Na druhej strane špekulácia je založená na odhadovaní psychológie davu. Keynes hovorí, že špekulácia je pre trh škodlivá a hnaná snahou dosiahnuť vysokú likviditu. Z tohto dôvodu presadzoval obmedzenie likvidity trhu zavedením rôznych poplatkov a daní.

Drasnarova stratégia – Vyzdvihuje dve kľúčové vlastnosti každého investora, ktorými sú podľa neho chamtivosť a strach. Úspešnými na trhu sú podľa Drasnara tí investori, ktorí vedia tieto dve vlastnosti využiť vo svoj prospech. Trh sa vyvíja v závislosti na tom, ktorá vlastnosť prevláda. Rastový trend motivovaný chamtivosťou je striedaný zostupom po prevládnutí strachu, kedy dav ovláda panika (Patria, 2021).

1.4 Technická analýza

Zatiaľ čo sa fundamentálna analýza zameriava na rozbor makroekonomických ukazovateľov, technická analýza sa zameriava predovšetkým na analýzu grafov a štatistických ukazovateľov. Technických analytikov nezaujíma, či sú akcie podhodnotené alebo nadhodnotené. Jediné, na čom skutočne záleží, sú údaje o obchodovaní s akciami v minulosti (ich cena a objem) a aké informácie tieto údaje môžu poskytnúť o budúcom pohybe akcií. V posledných rokoch si technická analýza získala popularitu nielen kvôli svojej jednoduchosti, ale aj vďaka svojmu univerzálnemu prístupu, čo znamená, že sa dá použiť na všetky segmenty trhu a na rôzne časové intervaly. Technická analýza je navyše metódou trhovej analýzy, ktorá nevyžaduje hlboké znalosti financií (Xtb, 2021).

Aby sme pochopili, na čom je založená technická analýza, je dôležité porozumieť trom zásadám technickej analýzy:

- **Trhové ceny zahŕňajú všetky informácie** – Jedným z predpokladov technickej analýzy je to, že trhový kurz odráža všetky relevantné informácie, ktoré sú o danom aktíve k dispozícii, teda ako fundamentálne, tak psychologické aj technické faktory. Pohyb cien na trhu je tak odrazom ponuky a dopytu, ktorá je ovplyvnená prichádzajúcimi informáciami a reakciami obchodníkov na tieto novo prichádzajúce informácie. Samozrejme, neočakávaná udalosť ako napríklad prírodná katastrofa alebo geopolitické napätie - môže ovplyvniť určitý trh, ale technického analytika dôvod nezaujíma. Technický analytik sa zameriava na samotné grafy a ich tvary, vzory či útvary, ktoré sa v nich vyskytujú (Sagefin, 2015).

- **Ceny sa pohybujú v trendoch** – akciové trhy sa pohybujú v troch trendoch, ktoré môžu stúpať (býčí trend), klesať (medvedí trend) alebo pohybovať sa do strany (bočný trend). Základným predpokladom je fakt, že trend má väčšiu pravdepodobnosť pokračovať vo svojom smere, ako by sa mal jeho smer zmeniť. Trend bude teda pokračovať do doby, kým nezačne vykazovať znaky zvrátenia trendu. Investor sa snaží tieto trendy identifikovať čo najskôr a investovať v smere daného trendu (Hrebicik, 2020).
- **História sa môže opakovať** – V kontexte technickej analýzy sa cenový trend zvykne opakovať. Teda ak graf vykazuje podobné náznaky zmeny trendu ako v minulosti, dá sa predpokladať, že investori budú na to reagovať podobne ako v minulosti. Napríklad na rastúcich trhoch sú účastníci chamtiví a chcú nakupovať bez ohľadu na vysokú cenu. Rovnako tak v rámci klesajúceho trendu chcú účastníci trhu predávať bez ohľadu na nízke a neatraktívne ceny. Táto ľudská reakcia zaistuje, že sa cenová história opakuje (Zerodha, 2021).

1.4.1 Metódy technickej analýzy

Existuje mnoho typov technických ukazovateľov a väčšina odborníkov na technickú analýzu, nazývaných aj grafici alebo technici, zahŕňajú do investičných rozhodnutí viac ako jeden ukazovateľ. Z tohto dôvodu technická analýza využíva pri analyzovaní trhu široké spektrum rozličných nástrojov a metód. Medzi tie najpoužívanéjšie patria grafické metódy a technické indikátory.

Grafické metódy – Grafy sú kľúčom k technickej analýze. Podstatou chartingu je zaznamenávanie kurzových hodnôt do grafov a z nich následne vyčítanie aktuálneho rozloženia síl na trhu alebo impulzu pre rozhodnutie ohľadom predaja či kúpy akcie. Grafické metódy sa rozvinuli do stoviek rôznych podôb, no napriek tomu ich môžeme s cieľom priblíženia k metóde technickej analýzy zhrnúť do niekoľkých skupín:

- stĺpkové grafy (bar charts),
- sviečkové grafy (candle stick),
- čiarové grafy (line charts),
- point & figure grafy,
- equivolume grafy.

Technické indikátory – Technické indikátory sú matematické výpočty, ktoré umožňujú obchodníkom identifikovať, kedy aktívum dosiahlo svoj vrchol alebo sa dostalo na dno. Technické indikátory využívajú najmä historické dáta a objem obchodov na predikciu smerovania akciového trhu. Sú založené na matematických rovniciach vytvárajúcich hodnotu, ktorá sa následne vykresluje do grafov. Technické indikátory pomáhajú obchodníkom identifikovať trendy a prekúpené (overbought) alebo prepredané (oversold) situácie, z toho dôvodu je pochopenie technických indikátorov veľmi užitočné pri vytváraní obchodnej stratégie (Patria, 2021).

Existujú štyri hlavné typy technických indikátorov :

- **Trendové indikátory** – Tieto indikátory slúžia primárne na určenie smeru a sily trendu. Sú to takzvané oneskorujúce sa indikátory. To znamená, že sa snažia určiť a potvrdiť trend, ktorý už samozrejme začal. Zatiaľ čo indikátory hybnosti alebo oscilátory sa usilujú predurčiť takýto trend, teda ich snahou je zachytiť trend v jeho najranejšom zárodku. Preto sa im tiež hovorí predstihové indikátory. Pri tomto type indikátorov sú najviac používanými kľzavý priemer (Moving average) alebo MACD (Moving average convergence/divergence) (Hodan, 2009).
- **Momentum indikátory (indikátory hybnosti)** - Indikátor momentum býva často označovaný skratkou MOM. Je to oscilátor, ktorého základnou podstatou je merať silu a rýchlosť trendu. Silnejúce momentum znamená, že trend naberá na sile. Slabnúce momentum naopak znamená, že trend „stráca dych“, a tak môžeme čoskoro očakávať jeho koniec, korekciu, alebo dokonca otočenie trendu. Výhoda indikátora momentum je, že nás často dokáže informovať o možnej zmene trendu s relatívne dostatočným predstihom. Momentum sa vypočíta nasledovne: $M = (CP/CP_n) \cdot 100$, kde M je aktuálna hodnota indikátora, CP zatváracia cena aktíva v aktuálnom dni a CP_n je zatváracia cena n-období dozadu. Príkladmi takýchto indikátorov sú Stochastický oscilátor, a taktiež Index relatívnej sily (RSI) (Nesnidal, 2005).
- **Objemové indikátory** – Merajú silu alebo slabosť trhu a vypovedajú o sile nastúpeného trendu. Rastúci objem potvrdzuje nastúpený trend, klesajúci objem naopak signalizuje možnú zmenu. Typické pre objemové indikátory je, že často prinášajú falošné signály a nie sú teda príliš spoľahlivé. Pracujú vždy s objemom obchodov, a to buď samostatne, alebo v kombinácii s kurzom. Medzi najpoužívanjšie objemové indikátory môžeme zaradiť On Balance Volume (OBV), či Money Flow Index (MFI) (Admiralmarkets, 2018).

- **Indikátory volatility** – Na hodnotenie aktivity trhu a cenovej dynamiky existuje indikátor nazývaný volatilita. Volatilita je rozsah cenových pohybov finančného inštrumentu za určité časové obdobie (deň, týždeň, mesiac atď.). Inými slovami, volatilita ukazuje, ako vysoko alebo nízko môže cena finančného inštrumentu v určitej dobe rásť alebo klesať. Volatilitu je možné vypočítať v percentách alebo bodoch. Napríklad ak akcie stáli na začiatku obchodnej relácie 100 USD a pripísali si (alebo stratili) 10 USD počas dňa, potom sa ich volatilita rovná 10 %. Na výpočet a použitie volatility v obchodovaní sa využívajú napríklad indikátory ako Bollingerove pásma (Bollinger Bands) alebo Priemer skutočného rozsahu (Average True Range - ATR) (RoboForex, 2021).

1.5 Neurónové siete

Neurónová sieť môže byť buď „skutočná“ biologická sieť neurónov, ako napríklad v ľudskom mozgu alebo umelá neurónová sieť, ako simulácia v počítači. Algoritmus učenia umelej neurónovej siete alebo jednoducho neurónová sieť, je výpočtový učiaci systém, ktorý využíva sieť funkcií na pochopenie a preloženie dátového vstupu jednej formy do požadovaného výstupu, zvyčajne v inej forme. Koncept umelej neurónovej siete bol inšpirovaný ľudskou biológiou a spôsobom, akým neuróny ľudského mozgu spolupracujú, aby pochopili vstupy z ľudských zmyslov. Neurónové siete sú len jedným z mnohých nástrojov a prístupov používaných v algoritmoch strojového učenia. Samotná neurónová sieť môže byť použitá ako súčasť mnohých rôznych algoritmov strojového učenia na spracovanie zložitých dátových vstupov do priestoru, ktorému počítače rozumejú. Neurónové siete majú taktiež veľké uplatnenie aj vo svete financií, kde pomáhajú najmä pri vývoji procesov, akými sú napríklad predikcie časových postupností (time series), algoritmické obchodovanie, klasifikácie cenných papierov a modelovanie úverových rizík (DeepAI, 2021).

1.5.1 Biologický verus umelý neurón


Umelé neurónové siete čerpajú veľkú časť svojej inšpirácie z biologického nervového systému. Je preto veľmi užitočné mať určité znalosti o tom, ako je tento systém organizovaný. Väčšina živých tvorov, ktoré majú schopnosť prispôbiť sa meniacemu sa prostrediu, potrebuje riadiacu jednotku, ktorá je schopná sa učiť. Vyššie vyvinuté zvieratá

a ľudia používajú na vykonávanie tejto úlohy veľmi zložité siete vysoko špecializovaných neurónov.

Biologický neurón je základnou stavebnou jednotkou neurónových sietí. U živých organizmoch je mozog riadiacou jednotkou neurónovej siete a má rôzne podjednotky, ktoré sa starajú o jednotlivé zmysly. Mozog je prepojený hustou sieťou nervov so zvyškom telesných senzorov a aktérov. V mozgu je približne 10^{11} neurónov. V biologických systémoch je neurón bunkou ako ktorákoľvek iná bunka tela, obsahujúca kód DNA a vytvárajúca sa rovnakým spôsobom ako ostatné bunky. Užitočnou analógiou je uvažovať o neuróne ako o strome (Vadapalli, 2020).

Neurón pozostáva z troch hlavných častí: dendrity, axón a bunkové telo (soma), ktoré môžeme definovať ako vetvy, korene a kmeň stromu. **Dendrit** (vetva stromu) je miesto, kde neurón prijíma vstup z iných buniek, resp. z okolitých neurónov. Dendrity sú ako vlákna rozvetvené v rôznych smeroch, rovnako ako konáre stromov a dokonca majú na sebe štruktúry podobné listom, ktoré sa nazývajú **tŕne**. **Axón** (korene stromu) je výstupná štruktúra neurónu. Každý neurón má jeden axón. Keď sa neurón chce rozprávať s iným neurónom, vyšle elektrickú správu, nazývanú aj akčný potenciál, cez celý axón. Axóny teda prenášajú impulzy z jedného neurónu na druhý a vytvárajú tým dominový efekt. Na zakončeníach axónu sa kontakt s dendritom iného neurónu uskutočňuje cez **synapsiu**. Synapsia prenáša informáciu iba jednosmerne a neuróny sa v nich priamo nedotýkajú, pretože je medzi nimi tzv. synaptická štrbina. **Soma** (kmeň stromu) je miesto, kde leží jadro, v ktorom je umiestnená DNA neurónu a kde sa vyrábajú proteíny, ktoré sa majú transportovať cez axón a dendrity (Woodruff, 2021).

Obrázok 1: Biologický neurón



Prameň: Vlastné spracovanie podľa Pavana Vadapalliho (2021).

Umelý neurón je výpočtový model inšpirovaný biologickým neurónom. Umelý neurón simuluje správanie biologického neurónu sčítaním hodnôt vstupov, ktoré dostáva. Ak je výsledok sčítania hodnôt nad nejakou prahovou hodnotou (threshold), vyšle na svoj výstup vlastný signál pomocou aktivačnej funkcie (activation function), ktorý potom prijímajú ostatné neuróny. Neurón však nemusí zaobchádzať s každým zo svojich vstupov rovnakou váhou (weight). Každý z jeho vstupov je možné upraviť jeho vynásobením nejakým váhovým faktorom. Povedzme, že ak by vstup A bol dvakrát taký dôležitý ako vstup B, potom by vstup A mal váhu 2. Váhy môžu byť aj záporné, ak je hodnota tohto vstupu nepodstatná (Hsu, 2020).


Umelý neurón môžeme vyjadriť nasledovným vzťahom:

$$y = f\left(b + \sum_{i=1}^n x_i w_i\right), kde$$

- b = zaujatosť (bias), uprednostnenie,
- x_i = vstupy neurónu,
- w_i = zodpovedajúce váhy vstupov,
- n = počet vstupov z prichádzajúcej vrstvy,
- i = počítadlo od 1 do n ,
- f = aktivačná funkcia f aplikovaná na vážený súčet vstupov neurónu,
- y = výstup neurónu.

(Sharma, 2017)

Obrázok 2: Umelý neurón



Prameň: Sharma (2017)


1.5.2 Typy aktivačných funkcií

Aktivačná funkcia rozhoduje o tom, či má byť neurón aktivovaný alebo nie. To znamená, že rozhodne, či je vstup neurónu do siete dôležitý alebo nie v procese predikcie pomocou jednoduchších matematických operácií. Úlohou aktivačnej funkcie je odvodiť výstup zo súboru vstupných hodnôt privádzaných do uzla (repliky neurónu) alebo vrstvy uzlov. Primárnym účelom aktivačných funkcií je však zaviesť nelineárne vlastnosti do neurónovej siete tým, že konvertujú lineárne vstupné signály uzla na nelineárne výstupné signály (Baheti, 2021).

Do typov nelineárnych aktivačných funkcií patria napríklad:

- **Sigmoid** – V umelých neurónových sieťach je sigmoidná funkcia nelineárna aktivačná funkcia, používaná predovšetkým v dopredných neurónových sieťach. Funkcia berie akúkoľvek skutočnú hodnotu ako vstup a vytvára výstupné hodnoty v rozsahu 0 až 1. Čím väčší je vstup (kladnejší), tým bližšie bude hodnota výstupu k 1,0 a naopak čím menší je vstup (zápornejší), tým bližšie bude hodnota výstupu k 0,0 (Brownlee, 2021).


Obrázok 3: Sigmoidná aktivačná funkcia



Prameň: Vlastné spracovanie

- **Hyperbolický tangens (Tanh)** – Hyperbolický tangens je veľmi podobný sigmoidnej aktivačnej funkcii a má dokonca rovnaký S - tvar. Funkcia berie akúkoľvek reálnu hodnotu ako vstup a vytvára výstupy v rozsahu -1 až 1. Čím väčší je vstup (kladnejší), tým bližšie bude hodnota výstupu k 1,0, resp. čím menší je vstup (zápornejší), tým bližšie bude hodnota výstupu k -1,0 (Brownlee, 2021).


Obrázok 4: Aktivačná funkcia hyperbolický tanges



Prameň: Vlastné spracovanie

- **ReLU(Rectified Linear unit)** – ReLU je najčastejšie používanou aktivačnou funkciou pri tvorbe neurónových sietí. Funkcia vráti 0, ak dostane akýkoľvek záporný vstup a v opačnom prípade pre akúkoľvek kladnú vstupnú hodnotu vráti túto hodnotu späť (Becker, 2018).

Obrázok 5: Aktivačná funkcia ReLU



Prameň: Vlastné spracovanie

1.5.3 Štruktúra neurónovej siete

Štruktúra umelej neurónovej siete pozostáva z nasledujúcich komponentov:

- umelé neuróny,
- spojenia umelých neurónov,
- vrstvy umelých neurónov.

Neurónová sieť je tvorená umelými neurónmi, ktoré sú navzájom prepojené tak, že výstup jedného neurónu tvorí vstup ďalšieho. Prepojenia umelých neurónov vyjadrujú označenie cesty toku informácií s tým, že každé takéto prepojenie má určitú váhu. Prvky neurónovej siete sú prepojené vo vrstvách, ktoré tvoria architektúru siete. Vrstva je všeobecný pojem, ktorý sa vzťahuje na zbierku neurónov fungujúcich spoločne v určitej

hlbke v rámci neurónovej siete. Vrstvy umelej neurónovej siete môžeme rozdeliť na tri kategórie:

- **Vstupná vrstva** (input layer) – je vrstva vstupných neurónov, ktorá prenáša informácie z vonkajšieho sveta do siete. V tejto vrstve sa nevykonáva žiadny výpočet, vstupné neuróny iba odovzdávajú informácie skrytej vrstve.
- **Skrytá vrstva** (hidden layer) – Skrytá vrstva v umelej neurónovej sieti je vrstva medzi vstupnými vrstvami a výstupnými vrstvami, kde umelé neuróny prijímajú súbor vážených vstupov a vytvárajú výstup prostredníctvom aktivačnej funkcie. Stručne povedané, skryté vrstvy vykonávajú nelineárne transformácie vstupov vchádzajúcich do siete (Techopedia, 2018).
- **Výstupná vrstva** (output layer)– je vrstva zodpovedná za vytvorenie konečného výsledku. V neurónovej sieti musí byť vždy jedna výstupná vrstva. Výstupná vrstva preberá vstupy, ktoré prechádzajú z vrstiev pred ňou, vykonáva výpočty prostredníctvom svojich neurónov a následne produkuje výstup (Techopedia, 2021).

1.5.4 Trénovanie neurónovej siete

Jednou z najvýznamnejších vlastností umelej neurónovej siete je jej schopnosť učiť sa. Je však dôležité vysvetliť, čo učenie, resp. trénovanie neurónovej siete znamená. Učenie neurónu spočíva v jeho schopnosti, premeniť svoje konanie na vstupe alebo na výstupe v súlade s meniacim sa okolím. Treba brať do úvahy to, že aktivačná funkcia je fixná od začiatku a vstupný a výstupný vektor nie je možné zmeniť. Správanie neurónu je možné zmeniť len ak sa použijú váhy zodpovedajúce vstupnému vektoru. Cieľom trénovania neurónovej siete je získanie množiny dát, ktorá je optimálnym riešením danej úlohy. Na základe typu učiaceho procesu vieme učiace algoritmy rozdeliť na :

- a) **Riadené učenie** (supervised) – Riadené učenie je metóda, pri ktorej sa modely neurónových sietí trénujú pomocou „anotovaných“ údajov (labelled data). Znamená to, že niektoré údaje sú už označené správnou odpoveďou. Pri tomto type učenia modely potrebujú nájsť mapovaciu funkciu na mapovanie vstupnej premennej (X) s výstupnou premennou (Y), čo môžeme vyjadriť nasledujúcim vzorcom ako $Y=f(X)$. Riadené učenie potrebuje dohľad na trénovanie modelu, čo je podobné, ako keď sa študent učí veci v prítomnosti učiteľa. Riadené učenie sa môže použiť pre dva typy problémov, a to na klasifikáciu a regresiu (Javatpoint, 2021).

- b) Neriadené učenie** (unsupervised) – Ako už názov napovedá, tento typ učenia prebieha bez dozoru nejakého učiteľa. Tento proces učenia je nezávislý. Pri neriadenom učení sa vstupné vektory podobného typu kombinujú do zhlukov. Keď sa použije nový vstupný vzor, potom neurónová sieť poskytne výstupnú odpoveď označujúcu triedu, do ktorej vstupný vzor patrí. Preto pri tomto type učenia musí samotná sieť objaviť vzory z neoznačených súborov údajov a nájsť vzťah medzi vstupnými údajmi a výstupmi (Tutorialspoint, 2021).
- c) Spätnoväzobné učenie** (Reinforcement learning) – V tomto druhu učenia neurónových sietí sa tzv. agenti pokúšajú nájsť optimálny spôsob, ako dosiahnuť konkrétny cieľ alebo zlepšiť výkon pri konkrétnej úlohe v určitom prostredí. Keď agent vykoná akciu, ktorá smeruje k cieľu, dostane odmenu, resp. penalizáciu. Pri rozhodovaní sa agent spolieha na vlastné skúsenosti a skúmanie nových taktík, ktoré mu môžu priniesť lepšiu odmenu (Chandrakant, 2020).

Všeobecný postup učenia umelej neurónovej siete pozostáva z nasledujúcich krokov:

1. Náhodne inicializujeme váhy v našej neurónovej sieti
2. Prvú množinu vstupných hodnôt posielame do neurónovej siete, aby sme získali výstupnú hodnotu pomocou aktivačnej funkcie.
3. Porovnávame získanú výstupnú hodnotu s očakávanou výstupnou hodnotou a vypočítame chybu (error) pomocou chybovej funkcie.
4. Chybu preniesieme späť do siete a upravíme váhy podľa týchto informácií.
5. Následne opakujeme kroky 2. až 4. pre každú vstupnú hodnotu, ktorú máme v našej trénovacej sade až kým nie je chyba minimálna .
6. Keď bola celá trénovacia sada odoslaná cez neurónovú sieť, máme za sebou prvú epochu a následne vykonáme ďalšie epochy tým istým spôsobom, kým nedosiahneme požadované výsledky (Rubikscodex, 2018).

Medzi najpoužívanějšíe algoritmy učenia umelej neurónovej siete patria:

- **Dopredný algoritmus** (The feedforward algorithm) – dopredný algoritmus začína šírením vstupných hodnôt do vstupnej vrstvy, následne prechádza cez skrytú vrstvu (vrstvy) a ako posledné meria predikcie siete z poslednej výstupnej vrstvy, kde sa nakoniec vypočíta chyba siete na základe predikcií, ktoré sieť urobila. Táto chyba siete meria, ako ďaleko je daná neurónová sieť od dosiahnutia optimálnych výsledkov. Napríklad, ak je správny výstup hodnota 4 a predikcia siete je 1,3, potom

absolútna chyba siete je $4 - 1,3 = 2,7$. Pri počítaní chybovej funkcie sa najčastejšie využíva metóda strednej kvadratickej chyby (mean squared error), ktorá je matematicky definovaná nasledovne:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y - \hat{y}_i)^2$$

V danom vzorci je n počet výstupov siete, y je hodnota očakávaného výstupu a \hat{y} je hodnota predikovaného výstupu zo siete. Keď sa vypočíta chyba siete, fáza dopredného šírenia sa skončí a začne sa spätný prechod, v ktorom sa využíva algoritmus spätného šírenia chyby (McGonagle, 2021).

- **Algoritmus spätného šírenia chyby** (Backpropagation) – je algoritmus riadeného učenia umelých neurónových sietí využívajúci gradientový zostup (gradient descent). Na základe typu umelej neurónovej siete a chybovej funkcie algoritmus počíta gradient (čiastková derivácia) chybovej funkcie vzhľadom na váhy danej neurónovej siete. Gradient meria, ako veľmi sa zmení výstup funkcie, ak sa trochu zmenia vstupy. Časť názvu „spätného“ (back) vychádza zo skutočnosti, že výpočet gradientu postupuje spätne cez sieť, pričom ako prvý sa počíta gradient finálnej vrstvy váh a ako posledný sa počíta gradient prvej vrstvy váh. Jednotlivé čiastkové výpočty gradientu z jednej vrstvy sa opätovne použijú pri výpočte gradientu pre predchádzajúcu vrstvu. Keď je spätná fáza dokončená a sú známe parciálne derivácie, váhy možno aktualizovať pomocou gradientového zostupu. Tento proces sa opakuje, kým sa nenájde lokálne minimum alebo kým nie je splnené konvergenčné kritérium (Saeed, 2021).


1.6 Rekurentné neurónové siete

Rekurentná neurónová sieť (RNN) je špeciálny typ umelej neurónovej siete prispôsobenej na prácu s dátami z časových postupností alebo s dátami, ktoré zahŕňajú sekvencie. Sekvenčné dáta sú v podstate len usporiadané dáta, v ktorých súvisiace veci na seba nadväzujú. Príkladom môžu byť finančné dáta alebo sekvencia DNA. Bežné dopredné neurónové siete sú určené len pre dátové body, ktoré sú navzájom nezávislé. Ak však máme dáta v takej sekvencii, že jeden dátový bod závisí od predchádzajúceho dátového bodu, musíme upraviť neurónovú sieť tak, aby zahŕňala závislosti medzi týmito dátovými bodmi. Rekurentné neurónové siete využívajú koncept vnútornej pamäte (internal memory), ktorý im pomáha ukladať stavy alebo informácie predchádzajúcich vstupov na generovanie

d ďalšieho výstupu sekvencie. Jednoducho povedané, že vďaka svojej vnútornej pamäti si dokážu zapamätať dôležité veci o vstupe, ktorý dostali a následne veľmi presne predpovedať, čo príde ďalej. Pre lepšie pochopenie rekurentných neurónových sietí si ich v krátkosti porovnáme s doprednými neurónovými sieťami (Donges, 2021).

Rekurentné a dopredné neurónové siete získali svoje mená podľa spôsobu, akým smerujú informácie v sieti. V doprednej neurónovej sieti sa informácie pohybujú iba jedným smerom - od vstupnej vrstvy cez skryté vrstvy k výstupnej vrstve. Informácie sa pohybujú priamo po sieti a nikdy sa nedotknú uzla dvakrát. Dopredné neurónové siete si nepamätajú vstup, ktorý dostávajú, čím horšie predpovedajú, čo príde ďalej. Pretože dopredná sieť berie do úvahy iba aktuálny vstup, nemá pojem o poradí v čase. V rekurentných neurónových sieťach informácie prechádzajú tzv. slučkou (loop), čo znamená, že keď sieť vykonáva rozhodovanie, berie do úvahy aktuálny vstup a tiež to, čo sa naučila zo vstupov, ktoré dostala predtým. Nasledujúci obrázok č. 6 ilustruje rozdiel v toku informácií medzi rekurentnými a doprednými neurónovými sieťami.

Obrázok 6: Rekurentná a dopredná neurónová sieť



Prameň: Vlastné spracovanie


Ďalším dobrým spôsobom, ako ilustrovať koncept pamäte rekurrentnej neurónovej siete, je vysvetliť ho na príklade: Majme normálnu doprednú neurónovú sieť a ako vstup jej dáme slovo „neurón“ a ona spracuje slovo znak po znaku. V čase, keď dosiahne znak „r“, už zabudla na „n“, „e“, „u“, čo pre tento typ neurónovej siete takmer znemožňuje predpovedať, ktorý znak bude nasledovať. Rekurentná neurónová sieť si však tieto znaky

dokáže zapamätať vďaka svojej vnútornej pamäti. Vytvára výstup, skopíruje tento výstup a privádza ho späť do siete. Taktiež je potrebné si uvedomiť, že zatiaľ čo dopredné neurónové siete mapujú jeden vstup na jeden výstup, rekurentné neurónové siete môžu mapovať jeden k mnohým, mnoho k mnohým alebo mnoho k jednému.

Z toho dôvodu delíme rekurentné neurónové siete na:

- **One to One** – je základným a najtradičnejším typom rekurentnej neurónovej siete, ktorá poskytuje jeden výstup pre jeden vstup
- **One to Many** – je druh architektúry rekurentných neurónových sietí, ktorá sa používa v situáciách poskytujúcich viacero výstupov pre jeden vstup. Základným príkladom aplikácie tohto typu by bolo vytváranie hudby (generovanie hudobnej skladby z jednej hudobnej noty).
- **Many to One** – Ako už názov napovedá, tento druh modelu sa používa, keď je na poskytnutie jedného výstupu potrebných viacero vstupov. Príkladom môže byť model hodnotenia filmov, ktorý ako vstup berie texty recenzií a následne poskytuje hodnotenia filmov, ktoré sa môžu pohybovať na stupnici od 1 do 5.
- **Many to Many** – Tento model berie sekvenciu vstupov a generuje sekvenciu výstupov. Jedným z príkladov použitia modelu many to many môže byť strojový preklad (online prekladače) (Prasad, 2021).

Obrázok 7: Typy rekurentných neurónových sietí



Prameň: Donges (2021)

1.6.1 Problémy rekurentných neurónových sietí

Existujú dve hlavné prekážky, s ktorými sa rekurentné neurónové siete museli vysporiadať:

1. **Explodujúce gradienty** (Exploding gradients) – Tento problém nastáva, keď sa gradient chybovej funkcie stane príliš veľkým z dôvodu pribúdajúcich vrstiev neurónovej siete. Ak sa gradient zväčší, model sa stane nestabilným, v dôsledku čoho sa nebude môcť učiť z tréovacích údajov. Tento problém je možné jednoducho vyriešiť skrátením alebo stlačením gradientov.
2. **Miznúce gradienty** (Vanishing gradients) – Problém s miznúcimi gradientmi je presným opakom explodujúcich gradientov, čo znamená, že sa gradient chybovej funkcie znižuje, keď sa spätne vraciame cez každú vrstvu počas algoritmu spätného šírenia chyby. Ak je aktualizácia váh veľmi nízka, tréovací čas potom trvá príliš dlho a v najhoršom prípade môže viesť k úplnému zastaveniu tréovania neurónovej siete. Problém miznúceho gradientu sa vyskytuje pri sigmoidnej a tangensovej aktivačnej funkcii, pretože deriváty sigmoidných a tangensových aktivačných funkcií sú v rozmedzí 0 až 0,25 a 0 až 1. Aktualizované hodnoty hmotností sú preto malé a nové hodnoty hmotností sú veľmi podobné starým hodnotám, čo vedie k problému miznúcich gradientov. Tomuto problému sa môžeme vyhnúť využitím aktivačnej funkcie ReLU, pretože gradient je 0 pre záporný a nulový vstup a 1 pre kladný vstup (Huawei, 2021).

1.6.2 LSTM - Long short-term memory

Long Short Term Memory v skratke LSTM je špeciálny druh rekurentnej neurónovej siete schopný učiť sa dlhodobé sekvencie. Ide o model alebo architektúru, ktorá rozširuje pamäť rekurentných neurónových sietí. LSTM boli vyvinuté na riešenie problému explodovania a miznutia gradientov pri tréovaní rekurentných neurónových sietí. LSTM umožňujú rekurentným neurónovým sieťam zapamätať si vstupy počas dlhého časového obdobia. Je to preto, že LSTM uchováva informácie v pamäti, podobne ako pamäť počítača, a teda dokážu čítať, zapisovať a mazať informácie zo svojej pamäte. Túto pamäť možno považovať za ohradenú bunku, čo znamená, že bunka sa rozhoduje, či uloží alebo vymaže informácie (či otvorí brány alebo nie), na základe dôležitosti, ktorá sa informáciám pripisuje. Priradovanie dôležitosti sa deje prostredníctvom váh, ktoré sa tiež

algoritmus učí. Jednoducho povedané, že sa časom naučí, ktoré informácie sú dôležité a ktoré nie. Jednotky, resp. bunky LSTM siete pozostávajú z dvoch stavov a troch brán:

- **Brána zabúdania** (Forget gate) – Prvou časťou zastúpenou v architektúre LSTM je brána zabúdania, ktorej úlohou je mazať nepotrebné informácie z predchádzajúcich stavov. Ak je výstupná hodnota z predchádzajúcej vrstvy bližšia k 0, znamená to zabudnúť, resp. zmazať a čím bližšie je hodnota k 1, znamená to zachovať danú hodnotu.
- **Vstupná brána** (Input gate) – V tejto bráne sa rozhoduje, či vstup (informácia) smie vstúpiť do pamäťovej bunky. Jej aktivačnou funkciou je väčšinou sigmoida s rozsahom $[0,1]$.
- **Stav bunky** (Cell state) – Dlhodobá pamäť modelu, obsahuje informácie, ktoré prešli cez vstupnú bránu. Tieto informácie budú následne vstupmi pre ďalšiu jednotku LSTM.
- **Výstupná brána** (Output gate) – Je niekedy tiež nazývaná „ohniskovým“ vektorom. Rozhoduje o tom, ktoré informácie budú zachované a použité v ďalšom skrytom stave bunky.
- **Skrytý stav** – Krátkodobá pamäť modelu, nesie informáciu o predchádzajúcich vstupoch neurónovej siete. To znamená, že aktuálny výstup neurónovej siete závisí na všetkých predchádzajúcich vstupoch a na aktuálnom vstupe. Skrytý stav je v LSTM rekurentnej neurónovej sieti reprezentovaný funkciou hyperbolický tangens (SSLA, 2021).

2 Ciel' práce, metodika práce a metódy skúmania

V druhej kapitole diplomovej práce sa venujeme popísaniu primárneho cieľa práce, jej sekundárnych cieľov a metodike, čiže postupom a metódam, ktoré využijeme pri tvorbe programu na predikciu cien akcií pomocou neurónových sietí, ktorého implementáciu popíšeme v praktickej časti.

2.1 Ciel' práce

Primárnym cieľom tejto diplomovej práce je analýza výnosov akciových trhov využitím neurónových sietí, pomocou ktorých v praktickej časti vytvárame model neurónovej siete, ktorá na základe historických údajov dokáže vytvárať predikcie cien akcií určitých podnikov v danom sledovanom období. Výsledok práce má poukázať na využitie umelej inteligencie, resp. strojového učenia v oblasti akciových trhov. Aby sme dosiahli cieľ práce, vytýčili sme v prvom rade čiastkové ciele, ktoré považujeme za potrebné splniť. Čiastkovými cieľmi práce sú:

- vyhľadanie a zhromaždenie odbornej a relevantnej literatúry týkajúcej sa akciových trhov a neurónových sietí,
- oboznámenie sa s obsahom vybraných zdrojov a výber potrebných informácií o analýze výnosoch akciových trhoch a neurónových sieťach z týchto zdrojov,
- popis techník, ktoré sa využívajú pri analýze akciových trhov, a taktiež možnosti využitia strojového učenia, resp. neurónových sietí v oblasti akciových trhoch,
- popis rekurentných neurónových sietí, ktoré následne využívame v praktickej časti na predikciu cien akcií,
- popísanie implementácie programu na predikciu cien akcií danej spoločnosti s využitím LSTM rekurentnej neurónovej siete,
- zhodnotenie výsledného programu a budúci pohľad,
- popis použitých technológií a záverečná diskusia.

2.2 Metodika práce a metódy skúmania

Pri spracovaní témy diplomovej práce budeme využívať empirickú metódu pozorovania, ako najuniverzálnejšiu metódu empirického skúmania, ktorá nám bude poskytovať prvotné informácie o sledovaných skutočnostiach. Na začiatku zhromaždíme všetky potrebné informácie o akciových trhoch a spôsoboch analýzy výnosov akciových trhov. Následne sa presunieme k získavaniu informácií týkajúcich sa neurónových sietí, ako k jednej z najpoužívanějších techník analýzy akciových trhov. Pri samotnom kompletizovaní využijeme metódy analýzy a syntézy.

Na dosiahnutie čiastkových cieľov a hlavného cieľa tejto diplomovej práce bude nevyhnutným predpokladom zhromaždenie odbornej literatúry, zaoberajúcej sa neurónovými sieťami a ich využitím na akciových trhoch. Pri spracovávaní témy a tvorbe diplomovej práce sme čerpáme zväčša zo zahraničných publikácií ale najmä z internetových zdrojov, keďže o tejto téme je málo dostupných publikácií v slovenskom jazyku.

V prvej teoretickej kapitole sa zameriavame na vymedzenie pojmov, ktoré súvisia s analýzou akciových trhov a neurónovými sieťami. Agregáciou zjednotíme všetky potrebné informácie na plnohodnotné spracovanie predmetnej témy. Ďalším krokom bude popísanie jednotlivých metód, ktoré sa využívajú na analýzu akciových trhov, kde sa v neposlednom rade budeme venovať neurónovým sieťam, ako jednej z najpoužívanějších techník pri analýze výnosov akciových trhov. Následne použijeme metódu syntézy, ktorú potrebujeme na spojenie nadobudnutých poznatkov z použitých zdrojov.

V tretej praktickej kapitole, resp. vo výsledkoch diplomovej práce sa budeme zaoberať predikovaním cien akcií v jazyku Python pomocou vytvoreného modelu LSTM rekurentnej neurónovej siete s využitím Pythonovskej knižnice Keras. V jednotlivých podkapitolách po častiach rozoberieme, ako budeme postupovať pri implementácii programu na predikciu cien akcií nasledovne:

- Prvým krokom implementácie programu bude načítanie potrebných historických dát určitého podniku, ktoré využijeme na tréning a validáciu modelu neurónovej siete.
- Ďalej si v druhom kroku určíme, na základe akých historických dát chceme vytvárať predikcie, v našom prípade budeme využívať najmä uzatváracie ceny akcií, pomocou ktorých bude model neurónovej siete vykonávať predikcie uzatváracích cien akcií

daného podniku. Následne si tieto uzatváracie ceny pripravíme do podoby použiteľnej pre model neurónovej siete, jednoducho povedané budeme musieť dáta transformovať do potrebného formátu, keďže Keras model neurónovej siete, ktorý budeme vytvárať, prijíma vstupné dáta len v určitom tvare.

- Tretím krokom bude vytvorenie samotného modelu neurónovej siete pomocou knižnice Keras, kde si napríklad popíšeme z akých druhov vrstiev, počtu neurónov, epoch a veľkosti dávok, naše pripravené dáta budú vstupovať do procesu trénovania tejto neurónovej siete. Dôležitou časťou tejto fázy bude aj ohodnotenie výkonnosti modelu neurónovej siete po skončení trénovania na pripravených trénovacích a validačných dátach. Výkonnosť určíme pomocou metriky Mean absolute percentage error, ktorá nám po každej epoche poskytne výsledok rozdielu medzi skutočnými a predikovanými cenami akcií podniku za dané skúmané obdobie. Jednotlivé výsledky výkonnosti budú následne vykreslené na grafe.
- Vo štvrtom kroku sa budeme venovať testovaniu neurónovej siete, čo znamená, že budeme zisťovať výkonnosť modelu LSTM rekurentnej neurónovej siete na dátach, ktoré ešte pred tým nevidela, a teda sú pre ňu nové.
- Jednotlivé výsledky predikcií uzatváracích cien akcií, dosiahnuté pomocou testovacích dát, si následne graficky zobrazíme v piatom kroku. Na grafe, ktorý vytvoríme s využitím pythonovskej knižnice Matplotlib, sa bude nachádzať krivka vytvorená z predikovaných cien akcií, a taktiež krivka skutočných cien akcií daného podniku, pomocou ktorej vieme porovnať, ako sa predikcie cien zhodujú alebo odlišujú od skutočného vývoja cien akcií podniku v sledovanom období.
- V poslednom šiestom kroku implementácie programu budeme využívať model neurónovej siete na predikciu zajtrajšej, resp. najbližšej uzatváraciej ceny akcií sledovaného podniku, keď sa akciový trh znova otvorí.

Po skončení popisu implementácie sa v ďalšej podkapitole praktickej časti budeme venovať zhodnoteniu a budúcemu pohľadu na výsledný program. V tejto podkapitole rozoberieme výkonnosť modelu LSTM rekurentnej neurónovej siete a rozoberieme aj akým spôsobom je možné ju vylepšiť, aby dosahovala lepšie a optimálnejšie výsledky. Zhodnotením programu sa presunieme na prehľad použitých technológií, kde opíšeme jednotlivé knižnice a vývojové prostredia jazyku Python, ktoré využijeme pri tvorbe programu pre uľahčenie práce s neurónovými sieťami. Záverečnou podkapitolou praktickej časti tejto diplomovej práce bude diskusia, v ktorej poukážeme na to, či je umelá

inteligencia, v našom prípade nami vytvorený model LSTM rekurentnej neurónovej siete, schopná predvídať a adaptovať sa na neočakávané udalosti, ktoré môžu spôsobiť veľké zmeny vo vývoji cien akcií určitých spoločností. Posledným krokom bude formulácia záveru, ktorý zostavíme pomocou metódy indukcie a dedukcie na základe zistených informácií z jednotlivých kapitol diplomovej práce.

3 Výsledky práce

Investori a výskumníci sa neustále snažia predpovedať správanie akciového trhu. Presné predpovede môžu byť užitočné pri prijímaní včasných a správnych investičných rozhodnutí. V súčasnosti sa navrhuje veľa štatistických techník a techník založených na strojovom učení (machine learning), ktoré sú schopné predpovedať správanie akciového trhu. Neurónové siete patria medzi tie, ktoré majú potenciál modelovať nelineárne správanie trhu. Keďže existuje veľa rôznych typov neurónových sietí a množstvo faktorov môže ovplyvniť akciový trh, výber siete a výber údajov je mimoriadne dôležitý. V tejto práci sme sa preto rozhodli venovať najmä LSTM rekurentným neurónovým sieťam, ktoré sú považované za najpopulárnejšie modely hlbokého učenia (deep learning), používané pri predikcii akciových trhov, ale aj pri množstve iných úloh týkajúcich sa časových postupností. Ich základnou vlastnosťou je najmä to, že sú schopné ukladať minulé informácie, čo je podstatným faktorom pri predikcii cien akcií, pretože predchádzajúca cena akcie je rozhodujúca pri predpovedaní jej budúcej ceny. V našej záverečnej práci sa budeme venovať práve predikcii cien vybraných akcií pomocou LSTM rekurentnej neurónovej siete v jazyku Python. S využitím knižníc jazyku Python si ukážeme ako automaticky získame historické údaje o akciách a následne na tieto dáta prispôbime model LSTM rekurentnej neurónovej siete, aby sme predpovedali budúce ceny daných akcií (Mwiti, 2018).

3.1 Implementácia programu

Ako sme už spomínali v predchádzajúcej kapitole, cieľom tejto záverečnej práce bude vytvorenie programu v jazyku Python, ktorý na základe historických údajov o akciách a s využitím LSTM rekurentnej neurónovej siete bude schopný predikcie cien akcií za určité obdobie, ktoré budeme môcť následne porovnať so skutočným vývojom cien akcií, a taktiež dokáže predikovať budúcu cenu danej akcie. Nasledujúce podkapitoly budú preto zamerané na popis implementácie programu, kde si vysvetlíme ako sme postupovali pri vytváraní programu, resp. ktoré metódy a knižnice bolo potrebné použiť a prečo sme sa rozhodli pre ich použitie.

3.1.1 Načítanie dát

Prvým krokom pri tvorbe programu bola potreba načítania historických dát, poskytujúcich potrebné informácie o vývoji cien akcií za určité časové obdobie, ktoré nám budú slúžiť pre tréning neurónovej siete. Takéto dáta je možné získať a vložiť, resp. importovať do Pythonu viacerými spôsobmi. Pre import dát sme sa rozhodli využiť pythonovskú knižnicu Pandas Datareader, ktorá slúži na prístup k verejným finančným údajom z internetových zdrojov ako napríklad Yahoo! Finance, World Bank alebo Google Analytics. Pomocou tejto knižnice sme si z internetového zdroja Yahoo! Finance importovali potrebné dáta a vytvorili dátovú tabuľku (dataframe), pozostávajúcu z historických dát o vývoji cien akcií spoločnosti Tesla za obdobie od 1. 1. 2012 až po 1. 6. 2021.

Ďalej bolo nutné importované dáta zobraziť, aby sme videli v akej forme a akom počte sa nachádzajú, a či sa medzi nimi nenachádzajú prázdne hodnoty (null values). Tieto prázdne hodnoty sa môžu vyskytnúť pri importe dát a ich neodstránenie by spôsobilo problémy pri budúcom tréningu neurónovej siete. V prípade výskytu takýchto prázdnych miest by bolo nutné chýbajúce hodnoty pridať pomocou pythonovských metód pre vyplnenie potrebných miest ako napríklad interpolate(), ffill() a bfill(). Na obrázku č. 8 môžete vidieť výpis tvaru importovaných dát spoločnosti Tesla, kde sa nachádza 6 stĺpcov, pozostávajúcich z High, Low, Open, Close, Volume a Adjusted close hodnôt. Každý z nich obsahuje presne 2368 hodnôt, medzi ktorými sa nevyskytovala žiadna prázdna hodnota. Načítaním dát sme sa následne mohli posunúť do ďalšej fázy implementácie, ktorou bola príprava importovaných dát do formy použiteľnej pre tréning neurónovej siete.

Obrázok 8: Výpis historických údajov spoločnosti Tesla

	High	Low	Open	Close	Volume	Adj Close
Date						
2012-01-03	5.900	5.530	5.788	5.616	4640500.0	5.616
2012-01-04	5.734	5.500	5.642	5.542	3150500.0	5.542
2012-01-05	5.586	5.370	5.552	5.424	5027500.0	5.424
2012-01-06	5.558	5.282	5.440	5.382	4931500.0	5.382
2012-01-09	5.498	5.224	5.400	5.450	4485000.0	5.450
V danej tabuľke(dataframe) sa nachádza: 6 stĺpcov a v každom z nich je 2368 hodnôt						
Počet Null(prázdnych) hodnôt v tabuľke: 0						

Prameň: Vlastné spracovanie

3.1.2 Príprava dát na tréovanie neurónovej siete

Príprava dát začínala výberom potrebných údajov z dátovej tabuľky, na základe ktorých sa budeme snažiť vytvoriť predikcie cien akcií. V našom programe sme sa preto rozhodli vytvárať predikcie cien akcií pomocou uzatváracích (Close) hodnôt, resp. predikovať uzatváracie ceny (Close prices) akcií. Následne bolo potrebné tieto hodnoty uzatváracích cien za dané obdobie vyfiltrovať a transformovať do potrebného tvaru. Obrázok č. 9 vyjadruje, že sme si z dátovej tabuľky vytiahli iba uzatváracie ceny spoločnosti Tesla a predviedli ich na tvar 2D (dvoj dimenzionálneho) poľa s jedným stĺpcom a 2368 riadkami, kde každý riadok zodpovedal jednej hodnote uzatváraciej ceny. Transformáciu z 1D poľa na 2D pole sme vykonali pomocou funkcie `reshape` knižnice NumPy, ktorá Pythonu umožňuje rýchlo a efektívne vytvárať viac-dimenzionálne polia alebo matice a poskytuje množstvo operácií nad nimi. Hlavným dôvodom využívania numpy polí v našom programe bolo to, že model LSTM rekurentnej neurónovej siete, ktorý si bližšie popíšeme v nasledujúcej kapitole, sme vytvárali s využitím knižníc Keras a Tensorflow, ktorých funkcie pracujú s dátami v potrebných formátoch, resp. s dátami nachádzajúcimi sa v numpy poliach.

Obrázok 9: Prevedenie uzatváracích cien akcií do 2D poľa

Close		
Date		[2368 rows x 1 columns]
2012-01-03	5.616000	[[5.61600018]
2012-01-04	5.542000	[5.54199982]
2012-01-05	5.424000	[5.42399979]
2012-01-06	5.382000	[5.38199997]
2012-01-09	5.450000	[5.44999981]]
...


Prameň: Vlastné spracovanie

Ďalšou dôležitou úlohou bola potreba normalizácie dát. Normalizácia dát sa využíva v prípade rozličného rozsahu parametrov, aby sa zabránilo favorizovaniu údajov s vyššími hodnotami, aj keď s menšou výpovednou hodnotou. Pre tieto účely bola vybraná normalizácia pomocou MinMax škálovania knižnice Sklearn a jej modulu preprocessing, s využitím ktorého sme mohli naše dáta škálovať v intervale od 0 po 1. Min-max škálovanie sa vykonáva na základe rovnice:

$$X_{sc} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

V danej rovnici je X_{sc} škálovaná hodnota, X vstupná hodnota, X_{min} je minimálna a X_{max} je maximálna hodnota z danej množiny údajov. Po vykonaní normalizácie MinMax škálovaním vyzerali naše dáta tak, ako vidieť na obrázku č. 10:

Obrázok 10: Ukážka škálovania uzatváracích cien



Prameň: Vlastné spracovanie

Po škálovaní dát nasledovalo rozdelenie dát do dvoch dátových súborov potrebných pre tréning neurónovej siete, z ktorých nám jeden určuje koľko dní v minulosti chceme sledovať uzatváracie ceny akcií a druhý nám slúžil pre uzatváraciu cenu nasledujúceho dňa po danom sledovanom období. Pre účely programu sme sa rozhodli sledovať 60 dní uzatváracích cien v minulosti a na základe týchto dní sa budeme snažiť predpovedať vývoj uzatváracie ceny 61. dňa. Obsah dátových súborov môžeme popísať nasledovne:

- Prvý súbor vstupných dát s názvom „x_trenovacie_data“ pozostával z hodnôt uzatváracích cien za posledných 60 dní, ktoré chceme použiť na predikciu hodnoty uzatváracie ceny nasledujúceho 61 dňa. Prvé pole v tejto množine obsahovalo hodnoty dát od indexu 0 po index 59 (celkovo 60 hodnôt), ďalšie resp. druhé pole v poradí obsahovalo hodnoty od indexu 1 po index 60 (60 hodnôt), atď. Jednoduchšie povedané v tejto množine sa nachádzalo celkovo 2308 polí, kde jedno pole obsahovalo 60 hodnôt uzatváracích cien.
- Druhý súbor vstupných dát s názvom „y_trenovacie_data“ bola množina obsahujúca pole so 61. hodnotou umiestnenou na indexe 60, pole so 62. hodnotou umiestnenou na indexe 61, atď. Táto množina obsahovala taktiež 2308 polí, avšak v každom z nich sa nachádzala iba 1 hodnota uzatváracie ceny, resp. hodnota 61 dňa. Tieto hodnoty budú následne porovnávané v procese tréningu modelu s predikovanými hodnotami.

Po roztriedení dát do dvoch dátových množín sme z týchto množín vytvorili 2D numpy polia a následne bolo taktiež nutné previesť 2D pole prvého dátového súboru x_trenovacie_data do 3D pol'a. Je to z toho dôvodu, že model LSTM rekurentnej neurónovej siete, ktorý sme pomocou knižnice Keras vytvárali, prijíma vstupné údaje v špecifickom 3D formáte. Takéto pole obsahuje určitý počet vzoriek (samples), časových krokov (time steps)

a hodnôt (features), kde každé z menovaných predstavuje jednu dimenziu. Naše 3D pole vstupných údajov obsahovalo celkom 2308 vzoriek po 60 časových krokoch, kde jeden takýto krok obsahoval 1 hodnotu uzatváracej ceny akcie. Takto vytvorené a pripravené súbory dát nám umožnili prechod do fázy tvorby modelu LSTM rekurentnej neurónovej siete.

3.1.3 Vytvorenie a trénovanie LSTM modelu neurónovej siete

V tejto podkapitole si popíšeme ako sme postupovali pri tvorbe jednoduchého modelu LSTM rekurentnej neurónovej siete a následne ako prebiehalo trénovanie takejto neurónovej siete na predpripravených dátových súboroch.

Model rekurentnej neurónovej siete sme v programe vytvárali pomocou knižníc Keras a Tensorflow, ktoré značne uľahčujú a slúžia na prácu s neurónovými sieťami. Z knižnice Keras, ktorá poskytuje vysokoúrovňové API (Application Programming Interface) na tvorbu a trénovanie modelov neurónových sietí, sme si importovali tzv. Sequential (sekvenčný) model a potrebné vrstvy, z ktorých bude neurónová sieť pozostávať. Aplikačné programovacie rozhranie sekvenčného modelu knižnice Keras nám s využitím postupného usporiadania rôznych druhov neurónových vrstiev umožňuje vytvoriť potrebný model neurónovej siete s jedným vstupom a jedným výstupom. Na základe toho, že sa snažíme vytvoriť program na predikcie cien akcií, pomocou LSTM rekurentnej neurónovej siete, sme v sekvenčnom modeli využili tieto typy vrstiev neurónových sietí:

- **LSTM** – Prvým a najdôležitejším typom bola práve LSTM vrstva, ktorá je základom daného modelu rekurentnej neurónovej siete. LSTM vrstva z knižnice Keras využíva v procese trénovania 2 predvolené aktivačné funkcie. Jednou z nich je hiperbolický tangens slúžiaci na aktiváciu bunkového a skrytého stavu, druhou je sigmoidná aktivačná funkcia potrebná pre aktiváciu jednotlivých brán bunky. (Keras, 2022)
V danom modeli boli použité celkom 3 LSTM vrstvy, z ktorej každá pozostávala z 50 neurónov. V prvej LSTM vrstve (obrázok č. 11) bolo taktiež nutné nastaviť potrebný vstupný tvar, v akom majú dáta prvého súboru `x_trenovacie_data` vchádzať do neurónovej siete.
- **Dropout** – Dropout je technika, pri ktorej sa počas tréningu ignorujú náhodne vybrané neuróny, resp. náhodne „vypadnú“. Dropout je jednou z najpopulárnejších techník regularizácie na zníženie pretrénovania modelov neurónových sietí.

Pretrénovanie v modeli nastáva vtedy, keď ukazuje väčšiu presnosť na tréningových údajoch, ale menšiu presnosť na testovacích údajoch (Sharma, 2020).

Pomocou knižnice Keras sme vrstvy využívajúce dropout techniku pridali za každú LSTM vrstvu. Jednotlivým dropout vrstvám bolo nutné priradiť aj mieru vypadávania neurónov (Dropout rate), ktorá určuje percento deaktivovaných neurónov v predchádzajúcej vrstve. V modeli sme použili celkovo 3 Dropout vrstvy s mierou vypadávania neurónov 0.2 (20%).

- **Dense** – Je vrstva, ktorá často nasleduje po vrstvách LSTM a používa sa na výstup predikcie. Nazýva sa aj plne prepojená vrstva (fully connected layer), čo znamená, že každý neurón v dense vrstve dostáva vstup od všetkých neurónov svojej predchádzajúcej vrstvy. Dense vrstva predstavuje poslednú vrstvu v našom LSTM modeli. Jej úlohou je zmapovať 50 neurónov v tretej vrstve LSTM na jeden uzol, ktorého výstupná hodnota bude predikcia ďalšej uzatváraciej ceny (West, 2019).

Obrázok 11: Model LSTM rekurentnej neurónovej siete

```
# vytvorenie modelu
model = Sequential()
model.add(LSTM(units=50, return_sequences=True, input_shape=(x_trenovacie_data.shape[1], 1)))
model.add(Dropout(0.2))
model.add(LSTM(units=50, return_sequences=True))
model.add(Dropout(0.2))
model.add(LSTM(units=50))
model.add(Dropout(0.2))
model.add(Dense(units=1)) # predikcia ďalšej uzatváraciej ceny

# tréning modelu
model.compile(optimizer='adam', loss='mean_squared_error', metrics='mean_absolute_percentage_error')
history = model.fit(x_trenovacie_data, y_trenovacie_data, epochs=30, batch_size=29, validation_split=0.1)
```

Prameň: Vlastné spracovanie

Vytvorením modelu sme mohli následne prejsť na jeho tréning. Vo fáze tréningu bolo nutné model najskôr skompilovať (obrázok č. 11). Pomocou metódy compile knižnice Keras sme si zadefinovali nasledujúce veci:

- **Optimalizátor** (Optimizer) – V strojovom učení je optimalizácia dôležitým procesom, ktorý optimalizuje vstupné váhy porovnaním predikčnej a chybovej funkcie. Optimalizačné algoritmy sú zodpovedné za zníženie strát, resp. nesprávnych výsledkov predikcií a poskytujú oveľa presnejšie výsledky. Pre kompiláciu modelu sme použili optimalizátor Adam, ktorý je najpoužívanejším optimalizátorom pre tréning neurónových sietí. Optimalizátor Adam používa algoritmus, v ktorom sa na vykonanie procesu optimalizácie využíva metóda stochastického gradientu. Je

vhodný v prípadoch, keď je k dispozícii veľké množstvo dát a parametrov, a taktiež spotrebuje veľmi málo pamäte (Sharma, 2020).

- **Chybová funkcia** (loss function) – Chybovú funkciu sme sa pre daný model neurónovej siete rozhodli počítať pomocou metódy strednej kvadratickej chyby (mean squared error), ktorá nám určí rozdiel medzi skutočnou a predikovanou uzatváracou cenou akcií počas trénovacieho procesu.
- **Metriky** (Metrics) – Používajú sa na ohodnotenie výkonnosti modelov neurónových sietí. Metriky sú podobné chybovým funkciám, avšak nepoužívajú sa v trénovacom procese ale až pri testovaní modelu (Tutorialspoint, 2022).

Pre ohodnotenie modelu neurónovej siete sme použili metriku Mean absolute percentage error, ktorá nám určí percentuálny rozdiel medzi skutočnou a predikovanou uzatváracou cenou akcií danej spoločnosti.


Kompiláciou sme sa mohli presunúť na samotné trénovanie modelu. S využitím knižnice Keras a jej metódy fit, určenej na trénovanie modelov neurónových sietí, bolo ako prvé potrebné zadať na akých dátach chceme daný model trénovať. Pre trénovanie modelu sme použili dva predpripravené súbory dát `x_trenovacie_data` a `y_trenovacie_data`.

Ďalej sme si stanovili počet epoch a veľkosť dávok (batch size), v ktorých budú predpripravené dáta prechádzať cez našu neurónovú sieť. Jedna epocha znamená, že neurónová sieť videla všetky dáta práve raz, na druhej strane veľkosť dávky je počet vzoriek, ktoré zvyčajne prejdú cez neurónovú sieť naraz. V našom programe sme si stanovili presne 30 epoch, resp. naša sieť uvidela všetky dáta z dátových súborov celkovo 30 krát. Veľkosť jednej dávky bola 29, takže dáta boli prevádzané sieťou po 29 vzoriek z celkového počtu predpripravených dát.

Poslednou úlohou vo fáze trénovania modelu bolo rozdelenie predpripravených dát na trénovaciu a validačnú dátovú sadu. Na trénovacej sade sa neurónová sieť naučí nájst' najvhodnejšie nastavenie váh a biasov, tak aby dosahovali požadovaných výsledkov. Počas trénovania si model na validačnej sade, ktorá je časťou sady trénovacej, overuje vývoj chybovej funkcie a upravuje učiacu rýchlosť na základe úspešnosti. Tento proces overovania poskytuje informácie, ktoré nám pomáhajú vyladiť parametre a konfigurácie modelu. Vstupné dáta z predpripravených dátových súborov sme rozdelili na 90% trénovacích a 10% validačných dát.

Model sa následne trénoval na trénovacej sade a súčasne sa po každej epoche vykonalo hodnotenie modelu na validačnej sade. Po dokončení trénovania bolo potrebné zobrazit' výkonnosť vytvoreného modelu v jednotlivých epochách. Na zobrazenie výkonnosti sme využili API Pyplot z knižnice Matplotlib, pomocou ktorého sme si vytvorili graf výkonnosti na základe výsledkov Mean absolute percentage error metriky po každej epoche. Obrázok č.12 predstavuje nami vytvorený graf, ktorý znázorňuje výkonnosť modelu na dátach spoločnosti Tesla, vyjadrujúci percentuálny rozdiel predikovaných a skutočných cien v jednotlivých epochách. Na grafe môžeme vidieť, že v prvej epoche sa predikované ceny líšili od skutočných až o 16%, avšak postupne sa upravovali až nakoniec oscilovali na cca 6% pri posledných 10 epochách, čo znamená, že sa rozdiely predikovaných a skutočných cien v procese trénovania tohoto modelu postupne znižovali.

Obrázok 12: Graf výkonnosti vytvoreného modelu v jednotlivých epochách



Prameň: Vlastné spracovanie

3.1.4 Testovanie modelu

Po natrénovaní sme sa následne presunuli do fázy testovania nami vytvoreného modelu neurónovej siete. Hlavnou myšlienkou testovania je zistiť, ako si daný model bude počínať na už existujúcich dátach, ktoré ale ešte predtým nevidel, teda budú preňho nové.

Prvým krokom tejto fázy bolo vytvorenie a pripravenie testovacej sady dát, na ktorej model neurónovej siete testujeme. Príprava testovacích dát prebiehala rovnako ako vo fázach

načítania a prípravy dát na tréovanie modelu. To znamená, že ako prvé sme si s využitím knižnice Pandas Datareader z Yahoo! Finance importovali dáta a vytvorili dátovú tabuľku akcií spoločnosti Tesla za obdobie od 1. 6. 2021, čo bol posledný deň dát na tréovanie našej neurónovej siete, až po aktuálny deň 17. 2. 2022, kedy sme vykonávali testovanie modelu.

Keďže sa snažíme vytvárať predikcie na základe uzatváracích cien akcií, sme si z dátovej tabuľky následne vyfiltrovali iba hodnoty uzatváracích cien za dané testovacie obdobie. V danom testovacom období bolo celkovo 186 hodnôt uzatváracích cien akcií spoločnosti Tesla. Ďalšou dôležitou úlohou počas prípravy testovacích dát bola potreba pripočítať 60 hodnôt uzatváracích cien pred testovacím obdobím, resp. zlúčiť hodnoty od cca 1. 4. 2021 až po 1. 6. 2021 s naším testovacím obdobím. Týchto 60 pripočítaných hodnôt nám slúžilo na to, aby daný model dokázal predikovať ceny akcií 1. dňa, 2. dňa, atď. až po 60. deň v testovacom období, nakoľko program predikuje ceny nasledujúceho dňa na základe 60 dní z minulosti. Jednoducho povedané týchto 60 pripočítaných dní z minulosti nám slúžilo na predikciu hodnôt prvých 60 dní testovacieho obdobia. Výsledkom tohto zlúčenia bolo celkovo 246 hodnôt uzatváracích cien akcií spoločnosti Tesla určených na testovanie modelu, ktoré sme následne potrebovali previesť do požadovaného formátu a normalizovať.

Rovnako, ako aj pri príprave dát na tréovanie modelu sme pole týchto 246 hodnôt na testovanie modelu transformovali pomocou knižnice Numpy do 2D poľa s jedným stĺpcom a 246 riadkami, kde riadkami sú polia obsahujúce jednu hodnotu uzatváraciej ceny akcií Tesla za daný deň, vid' obrázok č. 13.

Obrázok 13: Prevedenie testovacích uzatváracích cien akcií do 2D poľa

Close		
Date		[246 rows x 1 columns]
2021-03-08	563.000000	[[563.00000000]
2021-03-09	673.580017	[673.58001709]
2021-03-10	668.059998	[668.05999756]
2021-03-11	699.599976	[699.59997559]
2021-03-12	693.729980	[693.72998047]
2021-03-15	707.940002	[707.94000244]

Prameň: Vlastné spracovanie

Ďalej sme si jednotlivé testovacie dáta normalizovali rovnakým spôsobom ako aj dáta na tréovanie modelu. Normalizácia testovacích dát bola vykonaná pomocou MinMax

škálovania knižnice Sklearn a jej modulu preprocessing, pomocou ktorého sme naše dáta škálovali v intervale od 0 po 1.

Po škálovaní dát nasledovalo roztriedenie dát do dátového súboru potrebného pre testovanie neurónovej siete, ktorý nám určuje koľko dní v minulosti sledujeme uzatváracie ceny akcií, na základe ktorých model neurónovej siete predikuje cenu nasledujúceho dňa po sledovanom období. Keďže sledujeme 60 dní uzatváracích cien v minulosti a na základe týchto dní predikujeme vývoj uzatváraciej ceny 61. dňa, obsah tohoto testovacieho dátového súboru môžeme popísať nasledovne:

- súbor testovacích dát s názvom „x_testovacie_data“ pozostával z hodnôt uzatváracích cien za posledných 60 dní, ktoré chceme použiť na predikciu hodnoty uzatváraciej ceny nasledujúceho 61 dňa. Prvé pole v tejto množine obsahovalo hodnoty dát od indexu 0 po index 59 (celkovo 60 hodnôt), ďalšie resp. druhé pole v poradí obsahovalo hodnoty od indexu 1 po index 60 (60 hodnôt), atď. Jednoduchšie povedané v tejto množine sa nachádzalo celkovo 186 polí, kde jedno takéto pole obsahovalo 60 hodnôt uzatváracích cien potrebných na predikciu nasledujúceho dňa.

Roztriedením dát do testovacieho dátového súboru x_testovacie_data sme z tejto množiny vytvorili 2D pole využitím funkcie array z knižnice NumPy a následne sme toto 2D pole testovacieho dátového súboru pretvarovali využitím ďalšej NumPy funkcie reshape do 3D poľa, pretože model neurónovej siete vytvorený pomocou knižnice Keras prijíma vstupné údaje v špecifickom 3D formáte. Výsledkom týchto úprav bolo 3D pole vstupných testovacích dát, obsahujúce celkom 186 vzoriek po 60 časových krokoch, kde jeden krok obsahoval 1 hodnotu uzatváraciej ceny akcií spoločnosti Tesla.

Posledným krokom po príprave testovacích dát bolo samotné testovanie modelu na týchto dátach. Testovaním modelu neurónovej siete sme sa snažili zistiť aké predikcie daný model vytvorí na základe toho, čo sa naučil v tréningovej fáze na tréningových dátach. Testovanie sme vykonávali pomocou knižnice Keras, ktorá nám umožňuje robiť predikcie uzatváracích cien akcií s využitím jej funkcie predict. Do tejto funkcie sme si jednoducho vložili súbor testovacích dát x_testovacie_data, na ktorých nami vytvorený model neurónovej siete následne vykonal predikcie. Keďže hodnoty predikcií boli z dôvodu škálovania v intervale od 0 po 1, bolo nutné ich previesť do spätnej formy s využitím funkcie inverse_transform knižnice Sklearn. Obrázok č. 14 zobrazuje v akej forme sa predikcie nachádzali pred a po prevedení do ich reálnej podoby. Prvý stĺpec nám znázorňuje prvých

päť predikovaných hodnôt nachádzajúcich sa v intervale od 0 po1, ktoré boli následne prevedené na reálne predikované hodnoty uzatváracích cien akcií.

Obrázok 14: Prevedenie výsledných predikcií na reálne ceny akcií

[[0.7003325]		[[619.8226]
[0.7087265]		[627.19696]
[0.71044827]		[628.7096]
[0.7023509]		[621.5958]
[0.69141954]		[611.99225]

Prameň: Vlastné spracovanie

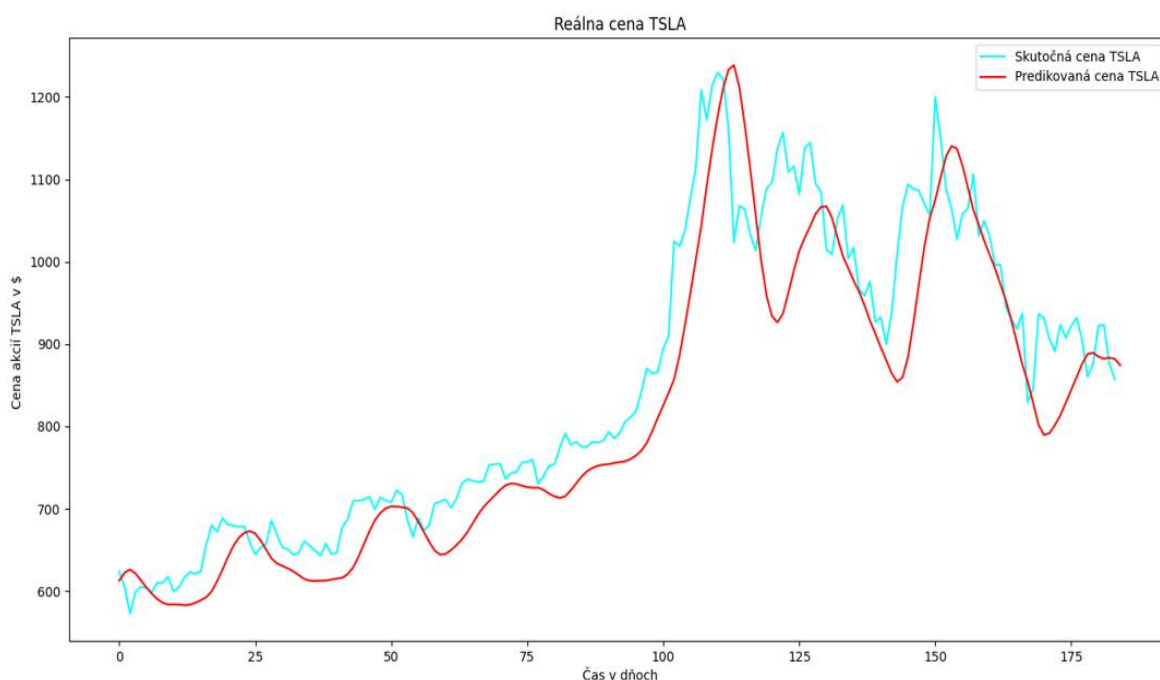
Predikcie uzatváracích cien akcií za dané testovacie obdobie, resp. výkonnosť modelu neurónovej siete na testovacích dátach si zobrazíme a taktiež popíšeme v nasledujúcej podkapitole.

3.1.5 Vykreslenie predikcií

Nakoľko výsledky predikcií z fázy testovania boli iba vo forme čísel, bolo potrebné tieto hodnoty zobrazit' na grafe, aby sme dokázali porovnať predikcie so skutočným vývojom cien akcií za dané sledované obdobie. Graf určujúci výkonnosť neurónovej siete na testovacích dátach sme vytvorili pomocou API Pyplot knižnice Matplotlib. Na danom grafe sa nachádzajú nasledovné prvky:

- **Os x** – vyjadruje počet dní skúmaného testovacieho obdobia
- **Os y** – je rozsah uzatváracích cien akcií určitého podniku v danom testovacom období v dolároch
- **Krivka predikovaných cien akcií** – znázorňuje výsledky predikcií modelu neurónovej siete, resp. vývoj predikovaných uzatváracích cien akcií, za skúmané testovacie obdobie
- **Krivka skutočných cien akcií** – určuje vývoj skutočných uzatváracích cien akcií daného podniku

Obrázok 15: Graf skutočných a predikovaných uzatváracích cien spoločnosti Tesla



Prameň: Vlastné spracovanie

Ako môžete vidieť vyššie, model dokáže celkom presne predpovedať trend uzatváracích cien akcií. Na grafe je taktiež vidieť aj nesprávne predikcie, ako napríklad medzi 120 až 125 dňom, kde sa model neurónovej siete rozhodol predikovať, že uzatváracie ceny akcií budú klesať, pričom krivka skutočného vývoja je v daných dňoch rastúca. Presnosť modelu je možné zvýšiť trénovaním s väčším množstvom údajov alebo úpravou parametrov modelu napríklad zvýšením LSTM vrstiev, zvýšením počtu epoch alebo znížením veľkosti dávok, čo však môže viesť k pretrénovaniu siete.

3.1.6 Predikcia ceny akcií nasledujúceho dňa

Nakoniec sme sa rozhodli otestovať nami vytvorenú LSTM rekurentnú neurónovú sieť ešte viac a predikovať budúcu, resp. najbližšiu uzatváraciu cenu akcií danej spoločnosti, keď bude akciový trh znovu otvorený.

Prvým krokom bola príprava dát, kde sme si rovnakým spôsobom ako aj v predchádzajúcich fázach implementácie programu, museli pripraviť dáta, potrebné pre vytvorenie budúcej predikcie. Na základe toho, že sa snažíme predikovať uzatváraciu cenu akcií 61. dňa pomocou cien 60 predchádzajúcich dní, sme si vytvorili dátový súbor pozostávajúci iba zo 60 minulých hodnôt uzatváracích cien, pretože sa chystáme predikovať iba jednu jedinečnú budúcu hodnotu uzatváracie ceny akcií. Na získanie 60 minulých hodnôt

uzatváracích cien akcií sme využili dátový súbor z testovacej fázy modelu neurónovej siete, z ktorého sme jednoducho zobrali posledných 60 hodnôt. Testovací dátový súbor sme využili z toho dôvodu, pretože pozostával z dát končiacich 17. 2. 2022, čo bol posledný deň, ku ktorému existovali historické dáta o vývoji cien akcií daných spoločností na akciovom trhu. Finálny dátový súbor pozostával z údajov o vývoji uzatvárajúcich cien akcií spoločnosti Tesla za obdobie od 23. 11. 2021 do 17. 2. 2022, s využitím ktorých budeme predikovať budúcu uzatváraciu cenu akcií, kedy sa trh opäť otvorí, čo v našom prípade bolo 18. 2. 2022.

Ďalším krokom bola normalizácia 60 hodnôt, resp. škálovanie jednotlivých hodnôt v intervale od 0 po 1 vrátane. Následne sme tieto zoškálované hodnoty priradili do prázdneho zoznamu s názvom `x_test_nasled`, ktoré sme pomocou funkcie `shape` pretvarovali do 2D numpy poľa. Takto vytvorené 2D pole s 60 hodnotami uzatváracích cien sme mohli transformovať využitím funkcie `reshape` do 3D poľa, pozostávajúceho z 1 vzorky po 60 časových krokoch, kde jeden krok obsahoval 1 hodnotu uzatváraciej ceny akcií spoločnosti Tesla. Keďže dáta boli pripravené v 3D formáte, aby mohli vstupovať do neurónovej siete, mohli sme sa presunúť na samotnú predikciu.

Posledným krokom bolo vytvorenie predikcie budúcej uzatváraciej ceny, kde sme využili funkciu `predict` na predpripravený dátový súbor. Na základe týchto posledných 60 dní uzatváracích cien akcií a toho, čo sa náš LSTM model neurónovej siete naučil v tréningovej fáze na tréningových dátach, nám program určil, že predpokladaná cena akcií spoločnosti Tesla na nasledujúci deň, t. j. 18. 2. 2022, bude presne 864,4669 \$, pričom skutočná uzatváracia cena bola v danom dni 856,98 \$.

3.2 Zhodnotenie výsledného programu a pohľad do budúcnosti

Investície do akcií sú predmetom záujmu mnohých investorov po celom svete. Rozhodovanie o tom, do akých investícií vložiť peniaze je zložitá úloha, ktorá je ovplyvnená mnohými faktormi. Pre úspešnú investíciu sa investori snažia predikovať budúci vývoj akciového trhu, kde aj malé vylepšenia v predikciách môžu efektívne viesť k značným ziskom. Dobrý predikčný systém pomáha investorom uskutočniť presnejšie a ziskovejšie investície, tým že im poskytuje podporné informácie, ako napríklad budúci smer cien akcií. Z tohto dôvodu je predpoveď ceny akcií veľmi dôležitý proces, ktorý môže byť hlavným prínosom pre investorov počas ich rozhodovania. Predpovedať budúci vývoj akciového trhu je v skutočnosti náročná úloha. Na predikcii sa totiž podieľajú aj ďalšie činitele, ako sú

fyzické a psychologické faktory, racionálne a iracionálne správanie atď. Všetky tieto faktory sa spájajú, v dôsledku čoho sú ceny akcií dynamické a nestále.

Existuje mnoho techník, ktoré investori využívajú na vytváranie predikcií cien akcií. V praktickej časti tejto práce sme sa venovali jednej z nich, a to konkrétne predikcií cien akcií pomocou LSTM rekurentných neurónových sietí, ktorá patrí medzi najefektívnejšie a najpoužívannejšie na predikovanie časových postupností. Program, ktorý sme vytvorili dokáže vytvárať predikcie cien akcií na základe jediného atribútu, konkrétne pomocou uzatváracích cien akcií danej spoločnosti. Z výsledkov tréovania a testovania daného vytvoreného modelu neurónovej siete, ktoré sme si predstavili v podkapitolách implementácie programu, môžeme povedať, že výkonnosť tohoto modelu bola v celku priaznivá a odlišnosti v skutočných a predikovaných uzatváracích cenách akcií boli minimálne.

O predikovanie cien akcií pomocou neurónových sietí sa pokúšajú milióny ľudí pomocou rôznych metód, často s oveľa väčším množstvom informácií a znalosťami v oblasti strojového učenia a akciových trhov, akými sme my pri tvorbe našej práce disponovali. Existuje však niekoľko vecí, ktorými sa treba riadiť, ak chceme dosiahnuť presnejšie a optimálnejšie výsledky predikcií modelu neurónovej siete. Medzi tie najdôležitejšie patria napríklad:

- **Použite toľko údajov, koľko vám príde pod ruku** – Jednoducho povedané, čím viac údajov použijeme na tréovanie modelu neurónovej siete, tým lepšia bude aj výkonnosť modelu. V našom prípade sme model neurónovej siete tréovali len na základe údajov týkajúcich sa uzatváracích cien akcií daného podniku za určité časové obdobie. Ak by sme však chceli dosiahnuť oveľa lepšie výsledky predikcií, bolo by vhodné využívať pri tréovaní modelu nie len hodnoty uzatváracích cien akcií, ale taktiež využiť viacero atribútov akými sú volatilita, objem, otváracie, najvyššie či najnižšie hodnoty cien akcií danej spoločnosti.
- **Testujte toľko, koľko môžete** – Na dosiahnutie lepšej výkonnosti je nutné model neurónovej siete neustále testovať na rôznych parametroch, teda napríklad skúšať na akom počte vrstiev, počte neurónov v jednotlivých vrstvách, počte epoch, veľkosti dávok, druhu aktivačných funkcií a iných konfiguráciách, bude model neurónovej siete vykazovať optimálne výsledky predikcií. Aj keď ladenie parametrov zaberie veľa času, je oveľa dôležitejšie ako výber samotného modelu neurónovej siete.

- **Je potrebné si byť vedomí „Black Swan“ (Čierna labuť) udalostí** – Black Swan alebo Black Swan teória je metaforou popisujúcou dôležité neočakávané udalosti, ktoré majú významný vplyv na spoločnosť. Tieto udalosti sa odchyľujú od toho, čo je bežné, a preto je ťažké ich predvídať. Pri finančnom trhu a jeho produktoch je už v niektorých prípadoch ťažšie odhaliť, či ide o skutočnú Black Swan udalosť alebo prirodzený vývoj situácie na trhu, ktorá nie je viditeľná väčšine pozorovateľov. Z tohto dôvodu je potrebné si byť vedomí Black Swan udalostí pri predikovaní vývoja akciového trhu s využitím neurónových sietí, keďže umelá inteligencia zatiaľ nedokáže takéto udalosti predpovedať, čo môže značne ovplyvniť výkonnosť modelov neurónových sietí pri vytváraní optimálnych predikcií. Neurónová sieť totiž neuvidí vznik Covidu-19, nedokáže zmerať náladu Vladimíra Putina alebo predpovedať finančnú krízu v roku 2008 (Matoušek, 2021).

3.3 Prehľad použitých technológií

Na implementáciu programu sme sa rozhodli použiť programovací jazyk Python (verzia 3.9). Python je vhodný na prácu s neurónovými sieťami, pretože ponúka obrovské množstvo knižníc, ktoré značne uľahčujú implementáciu a šetria veľké množstvo času, vďaka čomu sa dá aj veľký a komplexný projekt napísať v Pythone pomerne rýchlo. V našom programe boli použité nasledovné knižnice:

- **Pandas** – je open-source knižnica, ktorá slúži na manipuláciu a analýzu údajov. Používa sa na organizáciu a formátovanie zložitých údajov v tabuľkových štruktúrach nazývaných dataframes. Pandas je postavený na dvoch základných knižniciach Pythonu, ktorými sú Matplotlib a NumPy . Pandas funguje ako obal týchto knižníc, čo umožňuje prístup k mnohým metódam Matplotlib a NumPy s menším množstvom kódu, čo značne urýchľuje proces dátovej analýzy. V programe bola použitá verzia 1.3.4 (Raj, 2021).
- **Pandas Datareader** – mnohé finančné inštitúcie, akciové trhy a globálne banky poskytujú veľké množstvo údajov, ktoré verejne uchovávajú. Väčšina týchto údajov je dobre organizovaná, aktualizovaná a prístupná prostredníctvom rozhrania API (Application Programming Interface), ktoré ponúka programovacím jazykom ako je Python, spôsob ich stiahnutia a importu. Knižnica Pandas Datareader slúži na prístup k takýmto verejným finančným údajom z internetových zdrojov ako napríklad Yahoo! Financie, World Bank či Google Analytics a ich následný import do Pythonu

vo forme Dataframe (tabuľky). V našom programe sme využívali verziu 0.10.0 (Datasource, 2022).

- **Datetime** – v Pythone nie je dátum a čas vlastným dátovým typom. Z tohto dôvodu bolo nutné využiť knižnicu Datetime, ktorá nám poskytla funkcie na prácu s dátumami, časmi a časovými intervalmi, ktoré sme v našom programe využívali.
- **Matplotlib** – je komplexná knižnica na vytváranie statických, animovaných a interaktívnych vizualizácií v Pythone. Matplotlib je v podstate knižnica 2D grafov, ktorá má svoj pôvod v emulácii grafických príkazov MATLABu, od ktorého je ale nezávislá. Matplotlib ponúka viaceré druhy grafov ako je čiarový, stĺpcový, rozptylový alebo histogram. Intenzívne využíva knižnicu NumPy a ďalšie rozšírenia, aby poskytoval dobrý výkon aj pre veľké polia údajov. Pri implementácii programu sme využívali najmä jeho modul Pyplot, ktorý je zbierkou funkcií slúžiacich na úpravu vzhľadu grafov. V programe sme využívali verziu 3.4.3 (Shivaji, 2020).
- **Sklearn preprocessing** – knižnica vyvinutá firmou Scikit learn, ktorá poskytuje niekoľko bežných pomocných funkcií a tried transformátorov na zmenu vektorov nespracovaných prvkov na reprezentáciu, ktorá je vhodnejšia pre následné odhady. Z tejto knižnice sme využívali triedu MinMaxScaler pre normalizáciu údajov, resp. pomocou tejto triedy sme mohli škálovať naše vstupné údaje o cenách akcií do rozsahu 0 až 1. V programe využívame verziu 1.0.2 (Scikit-learn, 2022).
- **NumPy** – knižnica, ktorá Pythonu pridáva možnosť viac-dimenzionálnych polí, matice a množstvo operácií nad nimi (matematické, logické, Furierové transformácie...). Hlavné využitie tejto knižnice je vo vedeckej sfére. Je veľmi rozšírený - knižnice ako Keras a TensorFlow bez neho nedokážu fungovať (NumPy, 2022).
- **Tensorflow** – Tensorflow3 - open-source knižnica určená na strojové učenie. Vyvinutá tímom Google Brain pôvodne len pre interné využitie, no v roku 2015 bola uvoľnená pre verejnosť. Vďaka jej implementácii v C++ a platforme CUDA je rýchla a môže bežať aj na grafickej karte, čím ešte viac urýchli výpočty. Tensorflow dnes beží aj na mobiloch a prehliadačoch. V programe bola využívaná verzia 2.6.0 (Yegulalp, 2019).
- **Keras** – je vysokoúrovňové API pre tvorbu neurónových sietí napísané v jazyku Python, ktoré na pozadí využíva back-end z TensorFlow. Hlavnou myšlienkou je urýchlenie vývoja pri tvorbe neurónových modelov. To je dosiahnuté značným

zjednodušením syntaxe pre tvorbu neurónových sietí v Pythone. Zatiaľ, čo v originálnom programovaní za pomoci TensorFlow sú potrebné väčšie znalosti a pochopenie matematických súvislostí, Keras umožňuje rýchlo vytvoriť jednoduché modely neurónových sietí a následne ich adaptovať do požadovanej podoby. Keras umožňuje upravovať vytvorené modely na základe potreby a ďalej využívať aj ostatné externé knižnice. Hlavným problémom pri tvorbe modelu pomocou knižnice Keras bola v konečnom dôsledku iba správna úprava dát pred vložením do modelu, kedy bolo nutné dodržiavať niektoré základné princípy maticových výpočtov a polí, ktoré funkcie v knižnici Keras využívajú (Keras, 2022).

Samotnú implementáciu programu sme vykonávali s využitím nasledujúcich vývojových prostredíach:

- **PyCharm** – je integrované vývojové prostredie (IDE) používané v počítačovom programovaní, konkrétne pre jazyk Python. Pycharm bol vyvinutý českou spoločnosťou JetBrains, ktorá taktiež stojí za vytvorením populárneho IntelliJ IDEA IDE pre programovacie jazyky Java a JavaScript. PyCharm je dostupný ako multiplatformová aplikácia, ktorá poskytuje podporu pre verzie Python 2 aj Python 3 a je zároveň kompatibilná s operačnými systémami Linux, macOS a Windows (Arora, 2022).
- **Google Colab** – je nástroj, ktorý umožňuje komukoľvek písať a spúšťať ľubovoľný kód v programovacom jazyku Python cez prehliadač a je obzvlášť vhodný na strojové učenie a analýzu údajov. Google Colab bol vyvinutý spoločnosťou Google s cieľom poskytnúť bezplatný prístup ku GPU a TPU každému, kto ich potrebuje na vytvorenie modelu strojového učenia. Trénovanie modelov neurónových sietí, zaberie na CPU veľa času, na druhej strane GPU a TPU dokážu tieto modely trénovať v priebehu niekoľkých minút alebo sekúnd, čo bol aj hlavný dôvod, prečo sme Google Colab využili pri implementácii programu. Ako pri každom produkte od spoločnosti Google, aj na využívanie tejto technológie je potrebné disponovať iba Google účtom (Purgato, 2021).

3.4 Diskusia

V záverečnej diskusii tejto diplomovej práce sme sa rozhodli otestovať, ako sa dokáže náš vytvorený model LSTM rekurentnej neurónovej siete vysporiadať s black swan a inými neočakávanými udalosťami, ktoré môžu vo veľkej miere ovplyvniť vývoj cien akcií mnohých spoločností.


Pre tieto účely sme si vybrali za neočakávanú udalosť „zdravotnú krízu“ spôsobenú príchodom pandémie vírusu SARS-CoV-2, ktorá prerušila jedno z najdlhších období nepretržitého hospodárskeho rastu. Zdravotná kríza sa však na globálnej ekonomike podpísala oveľa tvrdsie ako predošlá finančná kríza, ktorá svet zasiahla v rokoch 2008 a 2009. Opatrenia, ktoré mali zabrániť šíreniu tejto choroby, ako napríklad lockdowny a zatváranie hraníc, mali dramatický vplyv na podnikateľské prostredie, najmä v odvetviach cestovného ruchu, leteckej a automobilovej dopravy, stavebníctva ako aj voľného času (leisure sectors). Na druhej strane iné odvetvia zažili nevídaný boom. Ide predovšetkým o farmaceutický priemysel alebo informačné a komunikačné technológie.

Ďalším krokom bol teda výber spoločnosti, ktorá počas pandémie utrpela najväčší pokles príjmov od jej vzniku. Z internetového zdroja Investment Monitor, ktorý vytvoril rebríček najviac ovplyvnených spoločností pandemiou Covid -19, sme si za testovací subjekt pre našu neurónovú sieť vybrali americkú spoločnosť Cedar Fair. Cedar Fair Entertainment je americká spoločnosť prevádzkujúca sieť zábavných parkov, ktorej ceny akcií na prelome rokov 2019 a 2020 z dôvodu pandémie spadli až o 87 %. Následne sme sa pustili do testovania modelu neurónovej siete na historických údajoch tejto spoločnosti, ktoré pozostávalo z nasledujúcich krokov:

1. Do programu sme si načítali historické údaje spoločnosti Cedar Fair z internetového zdroja Yahoo! Finance od 1. 1. 2005 až po začiatok pandémie, resp. 1. 1. 2020.
2. Zo všetkých načítaných údajov sme si vybrali len uzatváracie ceny akcií v tomto sledovanom období. Jednotlivé hodnoty uzatváracích cien boli ďalej prevedené do požadovaného formátu pre tréning a validáciu neurónovej siete.
3. Na takto pripravených tréningových a validačných dátach sme spustili samotné tréningy na 30 epochách a veľkosti dávok vstupných údajov po 29 hodnôt. Výkonnosť modelu, resp. percentuálne rozdiely v predikovaných a skutočných cenách vo fáze tréningu modelu v jednotlivých epochách, sú zobrazené na obrázku grafu č. 16. Tu môžeme vidieť, že ako aj v prípade predikcií cien akcií spoločnosti

Tesla, ktoré sme si opísali v podkapitolách implementácie programu, sú najväčšie rozdiely v skutočných a predikovaných cenách v počiatočných epochách, ktoré sa však v procese tréningu začali znižovať.

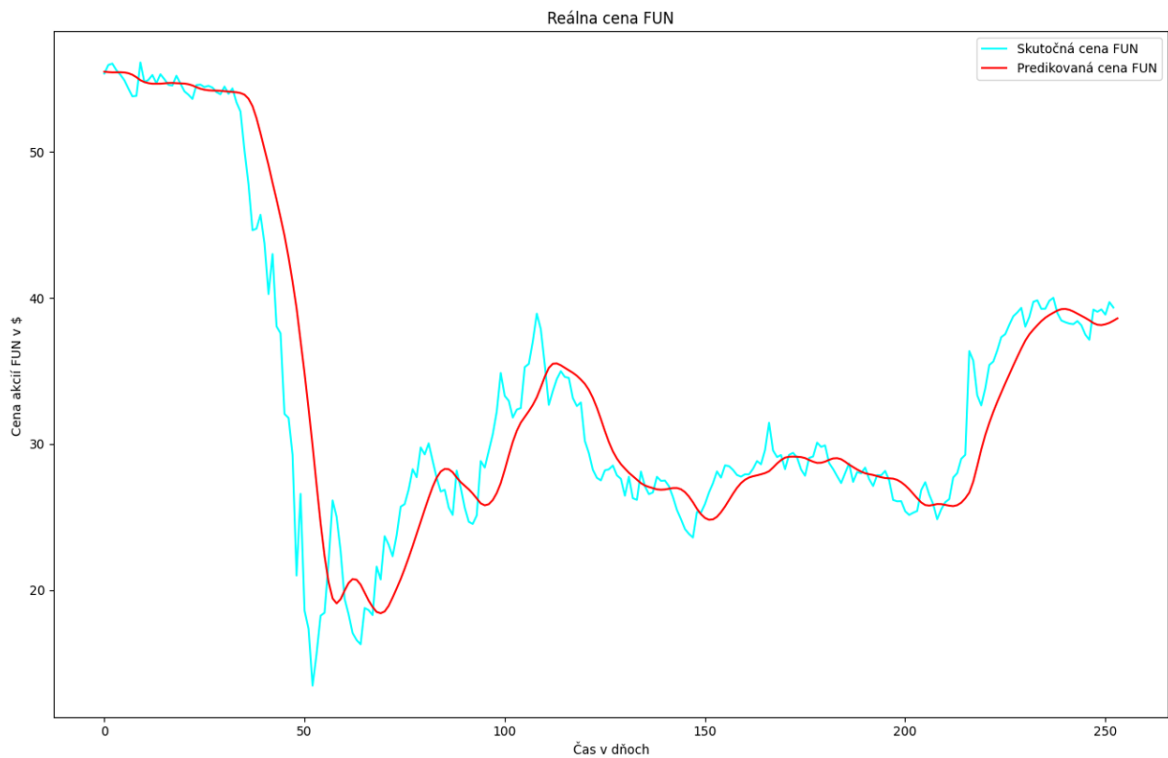
Obrázok 16: Graf výkonnosti modelu na dátach spoločnosti Cedar Fair



Prameň: Vlastné spracovanie

- Po natrénovaní siete pomocou tréningových dát sme prešli na samotné testovanie toho, ako si sieť poradí s neočakávanou udalosťou. Jednoducho povedané aké budú predikcie cien našej neurónovej siete na historických dátach spoločnosti Cedar Fair v čase pandémie, ktoré ešte nikdy pred tým nevidela. Do modelu neurónovej siete sme vložili pripravené testovacie dáta za obdobie od 1. 1. 2020 až 1. 1. 2021, kedy daná spoločnosť zaznamenala najväčší pokles cien akcií z dôvodu pandémie. Výsledky predikcií neurónovej siete na testovacích dátach, a taktiež skutočný vývoj uzatváracích cien akcií vyjadruje obrázok č. 17.

Obrázok 17: Graf skutočných a predikovaných uzatváracích cien Cedar Fair



Prameň: Vlastné spracovanie

Na obrázku vyššie je vidieť, ako sa model neurónovej siete vysporiadal s náhlým poklesom cien akcií spoločnosti Cedar Fair. Krivka skutočného vývoja uzatváracích cien akcií začala po 32. dni rapídne klesať, avšak naša neurónová sieť stále pokračovala vo vytváraní mierne klesajúcich predikcií ešte ďalšie 4 dni, po ktorých sa následne prispôbila skutočnému vývoju cien. V závere diskusie môžeme teda na základe zistených výsledkov predikcií zhodnotiť, že sieť sa dokáže adaptovať aj na neočakávané udalosti, ale predpovedať ich nedokáže.

Záver

Investovanie a obchodovanie na akciových trhoch patrí v súčasnosti medzi najrizikovejšie legálne činnosti. Kvalitné analýzy sú preto základom úspešného pôsobenia na týchto trhoch.

Cieľom tejto práce bolo zistiť možnosti využitia prostriedkov umelej inteligencie pre analýzu výnosov na akciových trhoch. Konkrétne sa jednalo o využitie neurónových sietí pri predikcii budúceho vývoja cien akcií spoločnosti Tesla, pričom nami vytvorený program je možné aplikovať na predikovanie cien akcií ľubovoľnej spoločnosti.

Implementáciu programu sme vykonávali pomocou programovacieho jazyka Python, pretože poskytuje veľké množstvo knižníc a API, ktoré značne uľahčujú a urýchľujú prácu s neurónovými sieťami. Samotný postup implementácie pozostával zo šiestich krokov, načítania dát, prípravy dát na tréning neurónovej siete, vytvorenia a tréningu modelu LSTM rekurentnej neurónovej siete pomocou knižnice Keras, testovania vytvoreného modelu, vykreslenia predikcií z testovacej fázy na grafe a posledným krokom bola predikcia budúcej uzatváraciej ceny akcií danej spoločnosti. Výsledkom implementácie je program, ktorý s využitím modelu LSTM rekurentnej neurónovej siete dokáže vytvárať predikcie cien akcií, na základe minulých hodnôt uzatváracích cien akcií danej spoločnosti. Následne sme v ďalšej podkapitole praktickej časti zhodnotili výsledný program a poukázali na možnosti jeho vylepšenia, pre dosiahnutie presnejších výsledkov predikcií cien akcií. V poslednej podkapitole sme sa venovali záverečnej diskusii, kde sme poukázali na to, ako umelá inteligencia, resp. neurónové siete dokážu reagovať na neočakávané udalosti, ktoré majú veľký vplyv na globálnu ekonomiku a vývoj akciových trhov.

V tejto práci sme využili množstvo nových poznatkov z oblasti umelej inteligencie ako aj z oblasti ekonomickej. Budúcnosť tejto práce by sa mohla orientovať na optimalizáciu modelov a testovania rôznych kombinácií vstupných dát. Takisto progres vývoja v kategórii výkonov počítačov a neustále sa zlepšujúcich metód môže priniesť značné zlepšenie predikcie modelov.

Použitá literatura

- [1] ADMIRALMARKETS. 2018. *Forex indikátory*. [online]. [cit. 2021-10-29]. Dostupné na internete: <<https://admiralmarkets.com/cz/education/articles/forex-indicators/on-balance-volume>>.
- [2] AMADEO, K. 2021. *An Introduction to the Financial Markets*. [online]. [cit. 2021-10-17]. Dostupné na internete: <<https://www.thebalance.com/an-introduction-to-the-financial-markets-3306233>>.
- [3] ARORA, S. K. 2022. *What is PyCharm? Features, Advantages & Disadvantages*. [online]. [cit. 2022-02-19]. Dostupné na internete: <<https://hackr.io/blog/what-is-pycharm>>.
- [4] BABS, T. 2018. *The Mathematics of Neural Networks*. [online]. [cit. 2021-11-04]. Dostupné na internete: <<https://medium.com/coinmonks/the-mathematics-of-neural-network-60a112dd3e05>>.
- [5] BAHETI, P. 2021. *12 Types of Neural Network Activation Functions: How to Choose?*. [online]. [cit. 2021-11-06]. Dostupné na internete: <<https://www.v7labs.com/blog/neural-networks-activation-functions>>.
- [6] BECKER, D. 2018. *Rectified Linear Units (ReLU) in Deep Learning*. [online]. [cit. 2021-11-07]. Dostupné na internete: <<https://www.kaggle.com/dansbecker/rectified-linear-units-relu-in-deep-learning>>.
- [7] BPWEALTH. 2021. *How do “top-down” and “bottom-up” investing differ?*. [online]. [cit. 2021-10-22]. Dostupné na internete: <<https://www.bpwealth.com/blog/top-down-vs-bottom-up-investing/>>.
- [8] BROWNLEE, J. 2021. *How to Choose an Activation Function for Deep Learning*. [online]. [cit. 2021-11-07]. Dostupné na internete: <<https://machinelearningmastery.com/choose-an-activation-function-for-deep-learning/>>.
- [9] DATASOURCE. 2022. *Using Python And Pandas Datareader to Analyze Financial Data*. [online]. [cit. 2022-02-12]. Dostupné na internete: <<https://www.datasource.ai/uploads/1c79c40efac8fff409e7c23fe8167d04.html>>.

- [10] DEEPAI. 2021. *What is a Neural Network?*. [online]. [cit. 2021-11-01]. Dostupné na internete: <<https://deepai.org/machine-learning-glossary-and-terms/neural-network>>.
- [11] DONGES, N. 2021. *A Guide to RNN: Understanding Recurrent Neural Networks and LSTM Networks*. [online]. [cit. 2021-11-16]. Dostupné na internete: <<https://builtin.com/data-science/recurrent-neural-networks-and-lstm>>.
- [12] EDELWEISS. 2019. *What Is Fundamental Analysis In Stock Market?*. [online]. [cit. 2021-10-18]. Dostupné na internete: <<https://www.edelweiss.in/investology/fundamental-analysis-218cf3/what-is-fundamental-analysis-in-stock-market-45347b>>.
- [13] ELEARNMARKETS. 2021. *The Complete Guide on Sector and Industry Analysis*. [online]. [cit. 2021-10-23]. Dostupné na internete: <<https://www.elearnmarkets.com/blog/guide-on-sector-industry-analysis/>>.
- [14] EUROEKONÓM. 2020. *Finančné trhy a finančný systém*. [online]. [cit. 2021-10-16]. Dostupné na internete: <https://www.euroekonom.sk/financie/financny-trh/financne-trhy-a-financny-system/?gclid=CjwKCAjwqeWKBhBFEiwABo_XBu-Dy9yrzAJiCbkH_o4VEkjTtgWy3eWHk18VpeppY60SxymW3VhKhoCOc4QAvD_BwE&fbclid=IwAR3hZjgxDHcS00ObttOQFGJQ5OAKIJSuhpSfdKmMqaNdXiJ7ffUsl-aRQfk>.
- [15] GANJU, H. 2018. *Fundamental Analysis: Top Down Approach*. [online]. [cit. 2021-10-22]. Dostupné na internete: <https://medium.com/@abc_40376/fundamental-analysis-top-down-approach-602ec5844971>.
- [16] HODAN, J. 2009. *Trendové indikátory*. [online]. [cit. 2021-10-28]. Dostupné na internete: <<https://www.fxstreet.cz/trendove-indikatory.html>>.
- [17] HREBÍČIK, M. 2020. *Technická analýza – úvod do problematiky*. [online]. [cit. 2021-10-26]. Dostupné na internete: <<https://www.burzove-spravy.sk/technicka-analyza-uvod-do-problematiky/>>.
- [18] HSU, H. 2020. *How Do Neural Network Systems Work?*. [online]. [cit. 2021-11-03]. Dostupné na internete: <<https://computerhistory.org/blog/how-do-neural-network-systems-work/>>.

- [19] HUAWEI. 2021. *Vanishing Gradient and Exploding Gradient*. [online]. [cit. 2021-11-19]. Dostupné na internete: <<https://forum.huawei.com/enterprise/en/vanishing-gradient-and-exploding-gradient/thread/739367-895>>.
- [20] CHANDRAKANT, K. 2020. *Reinforcement Learning with Neural Network*. [online]. [cit. 2021-11-10]. Dostupné na internete: <<https://www.baeldung.com/cs/reinforcement-learning-neural-network>>.
- [21] JAVATPOINT. 2021. *Difference between Supervised and Unsupervised Learning*. [online]. [cit. 2021-11-10]. Dostupné na internete: <<https://www.javatpoint.com/difference-between-supervised-and-unsupervised-learning>>.
- [22] KERAS. 2022. *Keras*. [online]. [cit. 2022-02-18]. Dostupné na internete: <<https://keras.io/>>.
- [23] KERAS. 2022. *LSTM layer*. [online]. [cit. 2022-02-10]. Dostupné na internete: <https://keras.io/api/layers/recurrent_layers/lstm/>.
- [24] MATOUŠEK, M. 2021. *Black Swan Theory – Černá labuť a Bitcoin*. [online]. [cit. 2022-02-01]. Dostupné na internete: <<https://btctip.cz/black-swan-theory-cerna-labut-a-bitcoin/>>.
- [25] MCGONAGLE, J. a kol. 2021. *Backpropagation*. [online]. [cit. 2021-11-12]. Dostupné na internete: <<https://brilliant.org/wiki/backpropagation/>>.
- [26] MITEV, B. 2021. *Introduction to Fundamental Analysis*. [online]. [cit. 2021-10-20]. Dostupné na internete: <<https://magnimetrics.com/introduction-to-fundamental-analysis/>>.
- [27] MWITI, D. 2018. *Using a Keras Long Short-Term Memory (LSTM) Model to Predict Stock Prices*. [online]. [cit. 2022-01-8]. Dostupné na internete: <<https://www.kdnuggets.com/2018/11/keras-long-short-term-memory-lstm-model-predict-stock-prices.html>>.
- [28] NESNÍDAL, T. 2005. *Zachyťte ten správný moment: indikátor Momentum*. [online]. [cit. 2021-10-28]. Dostupné na internete: <<https://www.financnik.cz/clanky/praxe/indikator-momentum-r222/>>.

- [29] NUMPY. 2022. *NumPy documentation*. [online]. [cit. 2022-02-15]. Dostupné na internete: <<https://numpy.org/doc/stable/>>.
- [30] PATRIA. 2021. *Akademie investování*. [online]. [cit. 2021-10-24]. Dostupné na internete: <<https://www.patria.cz/akademie/analyzy-investice-psychologie-trhu.html>>.
- [31] PATRIA. 2021. *Akademie investování*. [online]. [cit. 2021-10-27]. Dostupné na internete: <<https://www.patria.cz/akademie/analyzy-investice-technicka-analyza.html>>.
- [32] PRASAD, Y. 2021. *Types of RNN (Recurrent Neural Network)*. [online]. [cit. 2021-11-18]. Dostupné na internete: <<https://iq.opengenus.org/types-of-rnn/>>.
- [33] PURGATO, V. P. 2021. *Google Colab and Why You Should Use It*. [online]. [cit. 2022-02-22]. Dostupné na internete: <<https://medium.com/mllearning-ai/google-colab-and-why-you-should-use-it-28bf64a04717>>.
- [34] RAJ, N. 2021. *Pandas Functions for Data Analysis and Manipulation*. [online]. [cit. 2022-02-07]. Dostupné na internete: <<https://www.analyticsvidhya.com/blog/2021/03/pandas-functions-for-data-analysis-and-manipulation/>>.
- [35] ROBOFOREX. 2021. *Co je to Volatilita a jak ji využít při Tradingu*. [online]. [cit. 2021-10-29]. Dostupné na internete: <<https://blog.roboforex.com/cz/blog/2020/10/29/volatilita/>>.
- [36] RUBIKSCODE. 2018. *How do Artificial Neural Networks learn?*. [online]. [cit. 2021-11-12]. Dostupné na internete: <<https://rubikscore.net/2018/01/15/how-artificial-neural-networks-learn/>>.
- [37] SAEED, M. 2021. *An Introduction To Recurrent Neural Networks And The Math That Powers Them*. [online]. [cit. 2021-11-14]. Dostupné na internete: <<https://machinelearningmastery.com/an-introduction-to-recurrent-neural-networks-and-the-math-that-powers-them/>>.
- [38] SAGEFIN. 2015. *Principy technické analýzy*. [online]. [cit. 2021-10-26]. Dostupné na internete: <<https://www.sagefin.cz/clanky/vzdelani/technicka-analyza/principy-technicke-analyzy/>>.

- [39] SAMUELSON, P. E. – NORDHAUS, W. D. 2007. *Ekonomie*. 18. vydanie. Praha: Svoboda, 2019. 26 s. ISBN 978-80-205-0590-3.
- [40] SCIKIT-LEARN. 2022. *Preprocessing data*. [online]. [cit. 2022-02-14]. Dostupné na internete: <<https://scikit-learn.org/stable/modules/preprocessing.html#preprocessing>>.
- [41] SHARMA, A. 2017. *Understanding Activation Functions in Deep Learning*. [online]. [cit. 2021-11-04]. Dostupné na internete: <<https://learnopencv.com/understanding-activation-functions-in-deep-learning/>>.
- [42] SHARMA, P. 2020. *Keras Dropout Layer Explained for Beginners*. [online]. [cit. 2022-01-10]. Dostupné na internete: <<https://machinelearningknowledge.ai/keras-dropout-layer-explained-for-beginners/>>.
- [43] SHARMA, P. 2020. *Keras Optimizers Explained with Examples for Beginners*. [online]. [cit. 2022-01-13]. Dostupné na internete: <<https://machinelearningknowledge.ai/keras-optimizers-explained-with-examples-for-beginners/>>.
- [44] SHIVAJI. 2020. *What is matplotlib?*. [online]. [cit. 2022-02-12]. Dostupné na internete: <<https://www.quora.com/What-is-matplotlib>>.
- [45] SSLA. 2021. *Long Short Term Memory*. [online]. [cit. 2021-11-20]. Dostupné na internete: <<https://www.ssla.co.uk/long-short-term-memory/>>.
- [46] TECHOPEDIA. 2021. *Output Layer*. [online]. [cit. 2021-11-09]. Dostupné na internete: <<https://www.techopedia.com/definition/33263/output-layer-neural-networks>>.
- [47] TECHOPEDIA. 2018. *Hidden Layer*. [online]. [cit. 2021-11-09]. Dostupné na internete: <<https://www.techopedia.com/definition/33264/hidden-layer-neural-networks>>.
- [48] TUTORIALSPOINT. 2021. *Unsupervised Learning*. [online]. [cit. 2021-11-10]. Dostupné na internete: <https://www.tutorialspoint.com/artificial_neural_network/artificial_neural_network_unsupervised_learning.htm>.

- [49] TUTORIALSPOINT. 2022. *Keras - Model Compilation*. [online]. [cit. 2022-01-13]. Dostupné na internete: <https://www.tutorialspoint.com/keras/keras_model_compilation.htm>.
- [50] VADAPALLI, P. 2021. *Biological Neural Network: Importance, Components & Comparison*. [online]. [cit. 2021-11-02]. Dostupné na internete: <<https://www.upgrad.com/blog/biological-neural-network/>>.
- [51] WEST, M. 2019. *Explaining Recurrent Neural Networks*. [online]. [cit. 2022-01-12]. Dostupné na internete: <<https://www.bouvet.no/bouvet-deler/explaining-recurrent-neural-networks>>.
- [52] WOODRUFF, A. 2021. *What is a neuron?*. [online]. [cit. 2021-11-02]. Dostupné na internete: <<https://qbi.uq.edu.au/brain/brain-anatomy/what-neuron>>.
- [53] XTB. 2021. *What is technical analysis?*. [online]. [cit. 2021-10-25]. Dostupné na internete: <<https://www.xtb.com/en/what-is-technical-analysis-kb>>.
- [54] YEGULALP, S. 2019. *What is TensorFlow? The machine learning library explained*. [online]. [cit. 2022-02-15]. Dostupné na internete: <<https://www.infoworld.com/article/3278008/what-is-tensorflow-the-machine-learning-library-explained.html>>.
- [55] ZERODHA. 2021. *Technical Analysis*. [online]. [cit. 2021-10-27]. Dostupné na internete: <<https://zerodha.com/varsity/chapter/introducing-technical-analysis/>>.

Prílohy

Zdrojový kód programu:

```
1. # import knižníc
2. import datetime as dt
3. import matplotlib.pyplot as plt
4. import numpy as np
5. import pandas as pd
6. import pandas_datareader as web
7. from sklearn.preprocessing import MinMaxScaler
8. from tensorflow.keras.layers import Dense, LSTM, Dropout
9. from tensorflow.keras.models import Sequential
10.
11. # načítanie dát
12. podnik = 'TSLA'
13.
14. zaciatozne_data = dt.datetime(2012, 1, 1)
15. koncove_data = dt.datetime(2021, 6, 1)
16.
17. df = web.DataReader(podnik, 'yahoo', zaciatozne_data, koncove_data)
18.
19. # print(df.head(), '\n')
20. # print('V danej tabuľke(dataframe) sa nachádza: ', df.shape[1], 'stĺpcov a v každo
m z nich je ', df.shape[0], 'hodnôt')
21. # print('Počet Null(prázdných) hodnôt v tabuľke: ', df.isnull().sum().sum())
22. #
23. # fig, ax = plt.subplots(figsize=(16, 8))
24. # ax.set_facecolor('white')
25. # ax.plot(df['Close'], color='blue', label=f"Skutočná cena {podnik}")
26. # plt.title(f"Reálna cena {podnik} ")
27. # plt.xlabel('Čas')
28. # plt.ylabel(f"Cena akcií {podnik} ")
29. # plt.legend()
30. # plt.show()
31.
32. # príprava dát
33. data = df.filter(['Close'])
34. dataset = data.values.reshape(-1, 1)
35.
36. scaler = MinMaxScaler(feature_range=(0, 1))
37. skalovane_data = scaler.fit_transform(dataset)
38.
39. dni_pre_predikciu = 60
40.
41. x_trenovacie_data = []
42. y_trenovacie_data = []
43.
44. for x in range(dni_pre_predikciu, len(skalovane_data)):
45.     x_trenovacie_data.append(skalovane_data[x - dni_pre_predikciu:x, 0])
46.     y_trenovacie_data.append(skalovane_data[x, 0])
47.
48. x_trenovacie_data = np.array(x_trenovacie_data) # z viacerých 1D polí vytvoríme je
dno 2D pole pomocou NumPy
49. y_trenovacie_data = np.array(y_trenovacie_data)
50.
51. x_trenovacie_data = np.reshape(x_trenovacie_data, (x_trenovacie_data.shape[0], x_tr
enovacie_data.shape[1], 1))
52.
53. # vytvorenie modelu
54. model = Sequential()
55. model.add(LSTM(units=50, return_sequences=True, input_shape=(x_trenovacie_data.shap
e[1], 1)))
```

```

56. model.add(Dropout(0.2))
57. model.add(LSTM(units=50, return_sequences=True))
58. model.add(Dropout(0.2))
59. model.add(LSTM(units=50))
60. model.add(Dropout(0.2))
61. model.add(Dense(units=1)) # predikcia ďalšej uzatváracej ceny
62.
63. # trénovanie modelu
64. model.compile(optimizer='adam', loss='mean_squared_error', metrics='mean_absolute_p
percentage_error')
65. history = model.fit(x_trenovacie_data, y_trenovacie_data, epochs=30, batch_size=29,
validation_split=0.1)
66.
67. # zobrazenie grafu vykonnosti
68. plt.plot(history.history['val_mean_absolute_percentage_error'])
69. plt.title('Výkonnosť modelu')
70. plt.ylabel('Percentuálny rozdiel predikovanej a skutočnej ceny')
71. plt.xlabel('Epocha')
72. plt.legend(['Validácia'], loc='upper right')
73. plt.show()
74.
75. # testovanie modelu na existujúcich dátach
76.
77. # načítanie testovacích dát
78. zaciatočne_test_data = dt.datetime(2021, 6, 1)
79. koncové_test_data = dt.datetime(2022, 2, 17)
80.
81. test_data = web.DataReader(podnik, 'yahoo', zaciatočne_test_data, koncové_test_data
)
82. súčasne_data = test_data['Close'].values
83. celkove_data = pd.concat((df['Close'], test_data['Close']), axis=0) # zlúčenie riad
kov 2 dataframeov pomocou axis=0
84.
85. vstupy_modelu = celkove_data[len(celkove_data) - len(test_data) - dni_pre_predikciu
:].values
86. vstupy_modelu = vstupy_modelu.reshape(-1, 1)
87. vstupy_modelu = scaler.transform(vstupy_modelu)
88.
89. # vytvorenie predikcie na testovacích dátach
90. x_testovacie_data = []
91.
92. for x in range(dni_pre_predikciu, len(vstupy_modelu) + 1):
93.     x_testovacie_data.append(vstupy_modelu[x - dni_pre_predikciu:x, 0])
94.
95. x_testovacie_data = np.array(x_testovacie_data)
96. x_testovacie_data = np.reshape(x_testovacie_data, (x_testovacie_data.shape[0], x_te
stovacie_data.shape[1], 1))
97.
98. predikovane_ceny = model.predict(x_testovacie_data)
99. predikovane_ceny = scaler.inverse_transform(predikovane_ceny)
100.
101. # vykreslenie predikcii
102. fig, ax = plt.subplots(figsize=(16, 8))
103. ax.set_facecolor('white')
104. ax.plot(súčasne_data, color='cyan', label=f"Skutočná cena {podnik}")
105. ax.plot(predikovane_ceny, color='red', label=f"Predikovaná cena {podnik}")
106. plt.title(f"Reálna cena {podnik}")
107. plt.xlabel('Čas v dňoch')
108. plt.ylabel(f"Cena akcií {podnik} v $ ")
109. plt.legend()
110. plt.show()
111.
112. #PREDIKCIA NASLEDUJUCEHO DNA
113. #vytvorenie dataframe z close cien využitím testovacích dát z fázy testovania
114. novy_df_close = test_data.filter(['Close'])
115.

```

```

116. # zoberiem posledných 60 dní close cien
117. poslednych_60_dni = novy_df_close[-60:].values
118. # print(poslednych_60_dni)
119.
120. # zoscaleujem posledných 60 dní medzi 0 and 1
121. poslednych_60_dni_scaled = scaler.transform(poslednych_60_dni)
122.
123. # vytvorím prázdny list pre dáta na ktorých chcem vytvoriť predikciu nasledujúceho
    dňa
124. x_test_nasled = []
125.
126. #priradenie poslednych zoscaleovanych 60 dni do x_test_nasled
127. x_test_nasled.append(poslednych_60_dni_scaled)
128.
129. #prevedenie x_test_nasled dát do poľa pomocou numpy
130. x_test_nasled = np.array(x_test_nasled)
131.
132. #Reshape dát na 3D pole
133. x_test_nasled = np.reshape(x_test_nasled, (x_test_nasled.shape[0], x_test_nasled.sh
    ape[1], 1))
134.
135. #vytvorenie predikcie nasledujúceho dňa na základe x_test_nasled dát
136. pred_cena_nasled_dna = model.predict(x_test_nasled)
137.
138. # spätné scaleovanie hodnoty z intervalu (0,1) na reálnu cenu
139. pred_cena_nasled_dna = scaler.inverse_transform(pred_cena_nasled_dna)
140.
141. # výpis ceny na zajtra
142. print(f"Predikcia ceny akcie {podnik} na zajtra je: {pred_cena_nasled_dna}")

```